

CrossEarth：一种适用于通用遥感语义分割任务的地理空间视觉基础模型

邹阳功，IEEE 学生会员；魏志祥、王迪，IEEE 会员；胡晓星，IEEE 学生会员；马贤正、陈红瑞轩，IEEE 会员；贾玉茹、邓宇鹏，IEEE 会员；季振明、朱向伟，IEEE 会员；杨雪，IEEE 会员；横冈直人，IEEE 会员；张静，IEEE 高级会员；杜波，IEEE 高级会员；严俊奇，IEEE 高级会员；张良佩，IEEE 会士

摘要——由于遥感图像在位置、波长和传感器类型等方面存在巨大差异，因此，如何让遥感模型能够在不同场景下有效泛化，便成为一个至关重要的研究课题。不过，该领域的研究仍不够深入：(1)目前的跨域方法主要侧重于“领域适配”，即让模型适应已知的领域，而非未知的领域；(2)很少有研究专门针对遥感领域的泛化问题，尤其是在语义分割任务中。现有的相关模型都是为特定的未知领域而设计的，因此在处理其他未知场景时往往会出现欠拟合的问题；(3)现有的遥感基础模型往往更注重在特定领域的性能，而非跨域泛化能力。为此，我们提出了首个用于遥感领域语义分割的视觉基础模型。在语义分割方面，CrossEarth 表现出了出色的跨领域泛化能力。这得益于其专门设计的数据级处理流程以及模型级的多任务训练机制。此外，我们还构建了一个包含 32 种不同场景的 RSDG 基准数据集，这些场景涵盖了不同的地区、光谱波段、观测平台以及气候条件。该基准数据集有助于全面评估未来 RSDG 模型的泛化能力。通过大量实验，我们证明了 CrossEarth 相较于现有最先进方法的优越性。

索引词：领域泛化、视觉基础模型、遥感技术、语义分割、遮蔽图像建模。

一、引言

作为一种重要的数据来源，遥感图像能够详细记录地表各种地理对象的空间几何特征。该技术已被广泛应用于多个领域，包括精准农业[2]、城市规划[3][4][5]、环境监测[6]以及灾害评估[7][8]等。

在这些领域中，由于具备对像素级细节的精确识别能力，遥感语义分割被认为是一项至关重要的任务，它有助于准确且灵活地识别各类土地用途和覆盖类型。早期，遥感语义分割领域倾向于直接使用计算机视觉领域的传统分割模型，比如 PSPNet[9]、DeeplabV3+[10]和 DANet[11]。不过，由于这些模型主要是为自然图像而设计的，因此很难有效处理遥感图像。与自然场景相比，遥感图像面临着许多特殊挑战：(1)前景物体的尺寸差异很大；(2)存在微小物体和复杂的背景；(3)前景与背景之间的对比度极低。[12]为了解决这些问题，人们开发了多种针对遥感图像的分割模型[12][13][14][15][16]，从而提升了分割效果。

不过，理想情况下，训练图像和测试图像应来自相同的数据源，并且满足独立同分布的条件。但实际上，由于数据获取方式的多样性，遥感图像在多个方面存在显著差异：包括波段范围（如 RGB 与 IR-R-G）、地面采样距离（高分辨率与低分辨率）、以及获取平台的不同（如卫星与无人机）。此外，地表覆盖情况的差异也进一步增加了遥感图像的复杂性。除了地理位置的差异外，不同地理环境下的遥感图像在视觉上也有很大差别，比如城市和农村地区。这些差异给现有的遥感图像分割方法带来了巨大挑战。

在这种情况下，跨域语义分割近年来已成为遥感领域中一个非常重要的研究方向。许多优秀的研究成果[17][18][19][20][21]通过运用领域自适应技术[8][22][23][24][25][26][27][28][29][30][31][32]，极大地推动了该领域的发展。这些领域自适应方法通过利用迁移学习来弥补有标签源域与无标签目标域之间的差距，从而显著降低了对有标签数据的依赖。不过，领域自适应方法要求模型只能从源域适应到预定义的目标域，这限制了模型在各种未知领域的泛化能力——而这正是现实世界中面临的关键挑战之一，如图 1 左上角所示。

图 1. CrossEarth 的概览。现有的跨域遥感模型主要侧重于数据适配问题[8]、[22]、[23]、[24]、[25]、[26]、[27]、[28]、[29]、[30]、[31]、[32]。这些模型只能适应预先定义的目标领域，而无法处理各种未知的领域。另一方面，现有的 RSDG 方法也难以在跨域场景中实现良好的泛化能力。为了解决这些问题，我们提出了 CrossEarth——这是首个专为 RSDG 设计的视觉特征匹配模型。该模型能够有效弥补不同领域之间的差异，并能够处理多种语义分割任务。

相比之下，领域泛化技术[33][34][35][36]则能有效解决这一问题。该技术使得在源领域数据上训练得到的模型能够无需目标领域数据即可泛化到各种未知领域。因此，与数据增强技术相比，领域泛化技术在遥感语义分割中更具优势，因为获取目标领域数据既耗时又费力。不过，如图 1 左下角所示，目前关于遥感语义分割中领域泛化模型的研究仍然很少[37][38][39]。这些方法通常只针对特定场景进行训练，因此当应用于其他未知领域数据时，往往会出现欠拟合的问题。

从直觉上来看，DG 的概念与基础模型的理念不谋而合。基础模型旨在通过在大规模数据集上进行预训练来学习通用知识，从而能够以“零样本”的方式被应用到各种不同的场景中[40]。这自然意味着可以将 DG 研究与基础模型相结合。迄今为止，已经有许多先进的视觉基础模型被开发出来，用于遥感领域[40][41][42][43][44][45][46][47][48][49][50][51][52][53][54][55][56]。与传统的、针对特定场景的方法相比，这些视觉基础模型在各种遥感任务中都表现出了更出色的性能。不过，我们的文献综述表明，现有的遥感视觉基础模型主要侧重于同一数据源中的图像进行分割处理。在跨领域泛化能力方面，它们的理解能力仍然有限，而且几乎尚未被充分研究。

为此，迫切需要开发出强大的基础模型，以推动遥感领域泛化技术的研究。为了解决这一问题，我们推出了 CrossEarth——这是首个专为跨领域泛化条件下的遥感语义分割而设计的模型。如图 1 右侧所示，CrossEarth 具备出色的领域泛化能力，能够克服各种领域的差异，包括地区、分辨率、光谱波段、气候条件等。此外，CrossEarth 还具有极高的灵活性，可应用于各种遥感应用场景，从传统的遥感土地覆盖分类，到灾害评估、道路检测和建筑物识别等。这些都体现了 CrossEarth 在各种遥感应用中的适应性和有效性。

从技术上讲，CrossEarth 的泛化能力是通过数据操作与表示学习来实现的[33]。这一过程包含两个相互补充的步骤：地球风格注入和多任务训练。地球风格注入机制通过将地球领域的数据特征融入到原始数据中，从而扩大了训练数据的范围，使其能够涵盖那些可能未知的领域。这一方法提升了模型在数据层面的泛化能力。多任务训练则结合了语义分割和掩码图像建模技术，通过共享的 DINOv2[57]框架来提取共同的特征。这样一来，模型能够同时处理高层次和低层次的任务，从而学会那些对跨领域泛化至关重要的语义特征。此外，通过整合从原始图像中提取的详细地理空间信息，该模型还能进一步提升其泛化能力。我们进一步提升

了各项核心功能，从而更深入地理解了相关概念。总的来说，这些设计要素共同提升了 CrossEarth 的跨领域泛化能力，这一成就得益于在数据处理和模型架构方面的创新。

图 2. 我们在 32 个评估基准上对各种模型进行了测试。结果显示，CrossEarth 在各种分割场景下的 26 个测试项目中均取得了领先性能，展现了出色的泛化能力。所有结果均以 mIoU 分数来表示。

此外，由于在 RS 领域中，用于测试模型泛化能力的基准数据相当有限，我们收集了大量的 RS 语义分割数据集（具体细节稍后介绍），并将这些数据集应用到了 DG 场景中。在这些测试条件下，我们进行了大量实验。图 2 中的结果显示，与各种专门的 DA 模型和 VFMs 相比，CrossEarth 的泛化能力更为出色。本文的主要贡献如下：

我们推出了 CrossEarth，这是首个专为 RSDG 语义分割而设计的 VFM 模型。为此，我们采用了有效的“地球风格注入”技术以及多任务训练机制，从而从数据和模型架构层面提升了模型的跨领域泛化能力。得益于这些措施，CrossEarth 能够有效应对各种不同的领域挑战。

我们构建了一个包含 5 种不同领域场景下 32 种语义分割任务的基准测试集，用以评估 RSDG 方法的跨领域泛化能力。据我们所知，这是目前最全面的深度学习评估基准测试集。该基准测试集及相关的预处理脚本都将公开提供。

我们在这些测试基准上进行了大量实验。实验结果表明，CrossEarth 的表现处于业界领先水平，优于现有的所有开源视觉特征提取模型和深度学习模型。这充分体现了 CrossEarth 在克服各种领域差异方面的出色能力，包括不同地区、光谱波段、平台等因素带来的差异。

二、相关研究/文献

在大型语言模型带来的巨大推动下[58][59][60]，计算机视觉领域发生了重大的范式转变：人们不再依赖特定领域的模型，转而使用通用型的基础模型[61][62][63][64][65][66][67][68][69][70]。在各种视觉基础模型中[41][42][43][44][45][46][47][48][49][50][51][52][53][54][56][71]，也出现了许多创新成果。其中，Cha 等人[44]提出了首个专注于遥感图像检测与分割的十亿级模型。HyperSIGMA[49]则是首个用于多光谱遥感图像的十亿级视觉基础模型，能够支持分类、检测、解混、去噪和超分辨率等任务。Skysense[46]则能够捕捉时空信息，并在各种应用场景中表现出色。而 MTP[50]则采用了多任务预训练技术，目前被公认为是遥感图像语义分割领域最优秀的开源视觉基础模型。除了这些进展之外，最近的研究[72]从多任务和多层次的角度来探讨地球系统中的学习与预测问题。在这些研究中，各项任务在超图结构中相互协作、共同发挥作用。通过利用各路径之间的协同作用，该模型能够更准确地理解地球过程的本质，并在数据量有限的情况下仍能保持良好的泛化能力。此外，许多研究还将“任意分割模型”（SAM）应用到遥感领域中，例如基于文本的 PerSAM[73]，该模型展示了其在零样本和单样本分割任务中的出色性能，体现了基于提示的语音分割技术的巨大潜力。不过，由于在遥感领域对深度生成模型的研究还不够深入，现有遥感基础模型在跨领域任务中的表现仍有待进一步探索。鉴于跨领域泛化的目标与基础模型的“零样本学习”能力是一致的，我们提出了 CrossEarth——首个用于 RSDG 语义分割的 VFM 模型。希望这一成果能为该领域的未来研究提供借鉴。

三、方法

在本节中，我们首先在第三节 A 部分介绍了 CrossEarth 的整体架构。关于“地球风格注入”流程和“多任务训练”流程的详细信息，则分别会在第三节 B 部分和第三节 C 部分中介绍。

A. CrossEarth 概览

CrossEarth 由两个处理流程组成：一个是“地球风格注入”流程，另一个是“多任务训练”流程。在“地球风格注入”流程中，包含一个增强模块，该模块由风格预测器 p_s 、风格转移模块 p_t 以及掩码生成器 p_m 组成。在“多任务训练”流程中，包含两项任务：语义分割和掩码图像建模 (MIM)。在该流程中，我们使用 DINOv2 f_ϕ 作为特征提取模块。除了 f_ϕ 之外，语义分割流程还包括 Mask2Former 解码器 f_θ 、地理空间语义提取器(GSE) f_G 以及注入器 f_I 。MIM 流程则包含 ASPP[10]解码器 f_A 。

图 3. CrossEarth 的架构。该模型将“地球风格生成”流程与“多任务训练”流程相结合。在每次迭代中，样本选择器会决定是使用原始图像 X ，还是其经过风格转换后的版本 X_S ，再将其输入到分割处理流程中（包括主干网络 f_ϕ 、GSE f_G 、注入器 f_I ，以及解码器 f_θ ）。

与此同时，MIM 流程则通过 ASPP 解码器 f_A 来重建被遮盖的输入图像 X_M （如果选择了 X_S ，则同时重建 X_S 和 X_M ）。主干网络 f_ϕ 是共享的，但不会被修改；而 GSE 和注入器则仅应用于分割处理流程中。通过联合训练，可以优化 L_{Seg} 、 L_{MIM} 和 L_{Δ} 的值。

在每次训练迭代中，域内图像 $X \in \mathbb{R}^{H \times W \times 3}$ 会首先经过“地球风格注入”处理流程。具体而言，增强器会生成具有特定风格的图像 X_S ，而掩码生成器则会产生经过掩码处理的图像 X_M 。随后，伯努利分布 $Bernoulli(p)$ 会决定：分割流程是接收原始图像 X ($u = 0$)，还是接收经过风格处理的图像 X_S ($u = 1$)。最终选定的图像会被传递到主干网络 f_ϕ 中，经过 GSE 和各种增强器的进一步处理后，再由 f_θ 进行解码，从而得到分割预测结果 $\hat{Y}$ （针对 X ）或 $\hat{Y}_S$ （针对 X_S ）。与此同时，MIM 分支则分别以 X_M 单独作为输入，或同时以 X_M 和 X_S ($u = 1$) 作为输入。对于 X_M 和 X_S ，其主干网络特征会经过 ASPP 解码器 f_A 的处理，处理后的结果会被合并并传递到 $\hat{X}_M$ 或 $\hat{X}_S$ ，从而分别重建出原始图像和经过风格处理的图像。这一过程在算法 1 中有详细说明。

值得注意的是，Earth-Style Injection 机制仅专注于数据的处理，而不涉及参数的更新。在训练过程中，只有 GSE、Injector、Mask2Former 解码器以及 ASPP 解码器的参数会被更新。在下文中，我们将详细介绍 CrossEarth 中各个组件的具体实现方式及其设计理念。

B. 地面式注入管道

正如我们在引言中提到的，该流程旨在扩大训练数据分布的覆盖范围。因此，在本节中，我们首先探讨跨领域泛化过程中存在的分布问题。借鉴[74]、[75]的研究，我们将训练数据分布记为 D_{train} ，测试数据分布记为 D_{test} 。通常情况下，当模型在 D_{train} 上进行训练、而在

D_{test} 上进行测试时，由于分布上的差异，即 $D_{train} \cap D_{test} \approx \emptyset$ ，就会导致“领域差距”问题。在这种情况下，扩大 D_{train} 的覆盖范围[76]被视为提升模型泛化能力的有效方法。

为此，我们引入了一种数据增强方法，将与特定领域相关的数据所具有的风格特征嵌入到训练数据中。我们假设，所使用的训练数据的分布与未知场景的分布有部分重叠。因此，经过数据增强的训练数据实际上是由多个数据集合并而成的，从而确保了模型能够更好地泛化到各种未知领域。在本文中，我们使用的训练数据来自 Million-AID 数据集[77]，该数据集包含了超过一百万个来自全球各地的场景样本，已成为构建遥感基础模型的标准预训练数据源[43][44][50]。这种处理方式有效减少了不同领域之间的数据差异，提升了模型在各种未知场景中的泛化能力。

接下来我们详细说明各项技术细节。如图 3 所示，在生成风格化图像 X_S 之前，需要三个关键要素：由 p_s 提取用于风格注入的“地球风格嵌入” ε_o ；由 p_{sp_s} 提取作为风格基准的“领域内风格嵌入” ε ；以及由 p_{mp_m} 生成的用于结合前两种嵌入的“二进制掩码” M 。具体而言， p_{sp_s} 首先接收输入图像 X 和 X_O ，分别生成“地球风格嵌入” ε_o 和“领域内风格嵌入” ε 。

$$\begin{aligned}\varepsilon_o &= p_s(X_O) \\ \varepsilon &= p_s(X).\end{aligned}\tag{1}$$

在这里，我们以离线方式计算 ε_o 的均值和协方差矩阵，以此作为模拟嵌入 ε'_o 的初始值。采取这种方法的目的是为了减少在每次迭代中都重新计算 ε_o ，从而提高训练效率。

$$\varepsilon'_o \sim N(\text{Mean}, \text{Diag}(\text{SVD}(\text{Covariance}))),\tag{2}$$

其中， Diag 表示矩阵的对角元素， SVD 表示协方差矩阵的奇异值分解结果。Mask Generator p_m 接收输入数据 X 、遮罩比例 τ_m ，以及遮罩块的大小 B 。遮罩块的大小 B 决定了 X 中的数据会被分割成多少个遮罩块，而 τ_m 则负责确定哪些遮罩块需要被遮盖。关于这两个超参数的具体分析及选择方式，请参阅补充材料。下方的公式展示了 p_m 的具体运作过程：

$$M \sim U(0, 1)^{\lceil \frac{H}{B} \rceil \times \lceil \frac{W}{B} \rceil}.\tag{3}$$

$$M_i = \begin{cases} 1, & \text{if } M_i > \tau_m \\ 0, & \text{otherwise} \end{cases} \quad i = 1, \dots, \lceil \frac{H}{B} \rceil \times \lceil \frac{W}{B} \rceil\tag{4}$$

在生成掩码 M 时，我们参考了 MIC[78]中的方法。具体来说，我们会检查 M 矩阵中每个像素的值是否大于 τ_m 。如果大于，则该像素被设置为 1；否则，被设置为 0。之后，我们会将 M 矩阵的尺寸从 $(\lceil \frac{H}{B} \rceil, \lceil \frac{W}{B} \rceil)$ 调整为 (H, W) ，以便后续的图像生成工作。

最后，我们利用 p_t 将模拟出的地球样式注入到 X 中，再与 M 进行哈达玛积运算，从而得到 X_S ：

$$X_S = p_t(\varepsilon'_o, \varepsilon, X) \odot M + X \odot (1 - M).\tag{5}$$

除了生成 X_S 之外，该流程还会生成一张额外的遮罩图像 X_M ，以供后续的 MIM 任务使用。这一过程会引入可学习的视觉提示信息 $v \in \mathbb{R}^{H \times W \times 3}$ ，这些提示信息最初被设置为零

值，随后会与 M 模型相结合。 X_M 的生成过程可如下描述：

$$X_M = X \odot M \odot v. \quad (6)$$

值得注意的是，该流程中 p_s 和 p_t 所对应的结构实际上源自[79]中的轻量级网络模型。在我们的框架中，这些结构被保持不变，从而确保了风格增强模块的高效率以及其在大规模训练中的可扩展性。

C. 多任务训练流程

多项任务学习已被证明有助于提升模型的表征能力[50]。受此启发，我们同时考虑了两个任务：语义分割和 MIM，如图 3(b)和(c)所示。

语义分割流程：这是 CrossEarth 的主要训练流程，包括 DINOv2 主干网络[57]、GSE 模块[1]、Injector 模块[2]以及 Mask2Former 解码器[88][3]。值得注意的是，我们基准模型 Rein[89]的原始结构仅包含模块[4]和[5]。不过，CrossEarth 中的主干网络[6]和解码器[7]则属于额外添加的组件。

算法 1：利用样本门进行的多任务训练。

输入要求：输入图像 X 、分割标签 Y 、概率阈值 p 、最大迭代次数 T 、掩码生成器 $p_m(\tau_m, B)$ 、风格预测器 p_s 、风格转移模块 p_t 、DINOv2 架构 f_ϕ 、地理空间语义提取器 f_G 、注入器 f_I 、Mask2Former 解码器 f_θ 、ASPP 解码器 f_A 、可学习的视觉提示 v

- 1: 当 t 从 1 到 T 时，执行以下操作：
- 2: 根据公式(3)和(4)来生成 M 。
- 3: 通过(6)的运算来生成 X_M 。
- 4: 样本门: $u \sim \text{Bernoulli}(p)$ 5: 如果 $u = 1$ ，则
- 6: 通过(1)和(5)的运算来生成 X_S 。
- 7: 用公式(7)来计算 $\hat{Y}_S$ 的值。
- 8: 按照[89]中的方法，用 $(Y, \hat{Y}_S)$ 来计算 $\text{LsegL}_{\{\text{seg}\}}\text{Lseg}$ 的值。
- 9: 否则
- 10: 用 7 来计算 $\hat{Y}$ 的值。
- 11: 按照[89]中的方法，用 $(Y, \hat{Y})$ 来计算 $\text{LsegL}_{\{\text{seg}\}}\text{Lseg}$ 的值。
- 12: 结束条件满足则结束。
- 13: 用 8 来计算 $\hat{X}_M$ 的值。
- 14: 如果 $u = 1$ ，那么

15: 用 8 来计算 $\hat{X}_S$ 的值。

16: $L_{\text{mim}} = \|\hat{X}_M - X\|_\alpha + \|\hat{X}_S - X_S\|_\alpha, \alpha = 1 \text{ or } 2$ 17: $L_\Delta = \|\hat{X}_M - \hat{X}_S\|_1$ 18: 其他情况

19: $L_{\text{mim}} = \|\hat{X}_M - X\|_\alpha$ 20: $L_\Delta = 0$ 21: 结束条件判断

22: 全损: $L = L_{\text{seg}} + L_{\text{mim}} + L_\Delta$ 23: 结束。

Rein 并不适合用于 RS 图像的处理，因为它缺乏理解地理空间语义的能力。为了解决这个问题，我们引入了 GSE 来处理地理空间相关的查询，同时使用 Injector 来从主干网络提取的特征中获取相关的知识。

在设计 GSE 时，我们强调：所生成的地理空间查询既要有创造性，又要具有全局性。因此，我们努力让 GSE 的结构尽可能简单。从技术上讲，GSE 由五个卷积层组成[90]，这些卷积层都采用了 ReLU 激活函数[91]，如图 3 所示。与主干网络类似，GSE 也以 X 和 X_S 作为输入。随后，这些查询会被“注入器”用来提取地理空间特征。这一过程是通过简单的交叉注意力机制来实现的[92]：其中，主干网络产生的特征充当“键”和“值” k, v ，而地理空间特征则充当“查询” q 。具体而言，在注意力计算过程中，查询向量 q 会动态选择并赋予最相关的 k, v 对以适当的权重，从而生成更优质的特征，这些特征再被反馈到主干网络中。通过这一操作应用于多个主干层，地理空间语义不仅得以保留，而且在整个表示学习过程中不断得到强化。

整个语义分割的流程可以描述如下：

$$\hat{Y}_{\text{seg}} = \begin{cases} \hat{Y} \leftarrow f_\theta(f_I(f_G(X), f_\phi(X))), u = 0 \\ \hat{Y}_S \leftarrow f_\theta(f_I(f_G(X_S), f_\phi(X_S))), u = 1 \end{cases} \quad (7)$$

为了确保模型的泛化能力，我们在训练过程中同时使用了原始图像和经过处理的图像。与我们的基线模型 Rein[89]类似，分割损失的计算方式如下： Y 表示标注过的分割图，而损失函数则包含交叉熵损失和 Dice 损失[93]。

掩码图像建模流程：该流程旨在与分割处理流程相配合，从而实现更有效的地理空间特征学习。我们认为，采用这种建模流程有两个主要优势：(1) 同时完成分割和掩码图像建模任务，有助于确保模型提取的特征具有通用性且不受具体领域的影响；(2) 作为一种低层视觉任务，掩码图像建模有助于模型捕捉到更细致的全局信息，这符合地理空间编码器的设计目标。

因此，我们仍然利用主干网络 f_ϕ 来从 X_S 和 X_M 中提取特征。接着，我们引入 ASPP 解码器 f_A 来进行图像恢复。与那些仅处理最终特征的传统 ASPP 技术不同，我们的 MIM 流程会将主干网络各阶段的特征全部输入到 ASPP 解码器 f_A 中[10]，如图 3 所示。在这一过程中，每个阶段的特征都通过具有不同膨胀率的卷积层进行进一步处理，从而使 f_A 能够比标准 ASPP 方法捕获更多样化的信息。值得注意的是，我们在这一过程中禁用了 GSE 和注入器，以避免对 MIM 流程产生额外干扰，从而让主干网络能够充分发挥其潜力。最后，由 f_A 处理后的特征会经过一个普通的线性层，从而生成图像预测结果。这一过程也在图 3 中有所展示，其具体公式如下：

$$\hat{X} = \begin{cases} \hat{X}_M = \text{Linear}(f_A(f_\phi(X_M))), u = 0 \\ \hat{X}_M, \hat{X}_S = \text{Linear}(f_A(f_\phi(X_M, X_S))), u = 1 \end{cases} \quad (8)$$

在 MIM 流程中，重建损失 L_{MIM} 被定义为预测结果与相应真实图像之间的差异，该差异可通过 ℓ_1 或 ℓ_2 范数来衡量。具体而言，当 $u = 0$ 时，损失仅通过 $\hat{X}_M$ 和 X_M 来计算；而当 $u = 1$ 时，损失则由两部分组成： $\hat{X}_M$ 与 X_M 之间的距离，以及 $\hat{X}_S$ 与 X_S 之间的距离。损失函数的选择取决于所使用的数据集，相关讨论见第 V–G 节。此外，为了更好地约束图像重建过程，我们在 MIM 流程中引入了另一种损失度量 L_Δ ：通过对风格化处理后的图像预测 $\hat{X}_S$ 和经过遮罩处理的图像预测 $\hat{X}_M$ 计算 L1 损失。该损失度量可表示为 $L_\Delta(\hat{X}_S, \hat{X}_M)$ ，而多任务训练流程的总损失则如下所示：

$$L = \begin{cases} L_{\text{Seg}} + L_{\text{MIM}}, u = 0, \\ L_{\text{Seg}} + L_{\text{MIM}} + L_\Delta, u = 1. \end{cases} \quad (9)$$

值得注意的是， L_Δ 只有在 $u = 1$ 时才会被激活。而 X_M 则不是随机选取的，它始终被用于图像恢复处理。

IV. RSDG 语义分割基准测试

如上所述，目前的遥感社区缺乏用于评估模型泛化能力的统一标准。为了推动遥感语义分割领域的发展，我们整理了多种常用的遥感语义分割数据集，并将其应用到无人机场景中，具体内容见表一。我们的测试集包含了 32 种语义分割任务，涵盖了三种具体的应用场景：灾害评估、建筑物识别和道路检测。这些任务涉及五种不同的组合条件：(1) 未知区域；(2) 未知光谱波段；(3) 未知区域与未知光谱波段；(4) 未知区域与不同平台；(5) 未知区域与不同气候条件。具体而言，我们收集了包括 ISPRS Potsdam 和 Vaihingen [94]、RescueNet [83]、LoveDA [80]、WHU Building [95][96]、DeepGlobe [97]、Massachusetts [82]、CASID [87]、OpenEarthMap [84] 以及 GlobalRoadNet [85] 在内的多种常用遥感语义分割数据集。该基准测试的地理位置分布情况如图 4 所示。关于所使用的数据集以及基准测试的构建方式，请参阅补充材料以获取更多详细信息。

图 4. CrossEarth 基准测试的地理分布情况，可见该测试涵盖了六大洲数百座城市。

V. 实验部分

A. 初步阶段/初步调查

为了全面了解各个领域中的不足之处，并验证 CrossEarth 模型的普适性，我们在构建的 RSDG 基准测试平台上，将该模型与一系列具有代表性的模型进行了对比测试。

具体来说，我们选择了 DAFormer[98]、HRDA[100]、SSL4EO–MoCo(S12–MoCo)[106]、SSL4EO–DINO(S12–DINO)[106]、SSL4EO–MAE(S12–MAE)[106]、Remote–CLIP[105]、DOFA[103]、SateMAE[56]、ScaleMAE[104]、MTP[50] 和 Rein[89] 作为比较对象。其中，

我们采用了 DAFormer 和 HRDA 的扩展 DG 版本[107]。值得注意的是，CrossEarth 是首个用于 RSDG 的 VFM 模型。

在所有实验中，我们将迭代次数设置为 30K，批量大小为 1。模型优化采用 AdamW 优化器 [108]，学习率为 $1e-4$ 。在训练对比模型时，我们严格遵循这些模型的原始设置，包括所使用的优化器、学习率以及其他相关参数。对于 MIM 损失函数，CASID 实验中我们使用 L1 损失函数；而其他数据集则采用均方误差(MSE)损失函数。所有实验均使用 Pytorch 在 NVIDIA V100 显卡上完成。

表一

RSDG 基准测试的构成方式如下：我们根据源数据集与未见过的目标数据集之间的主要领域差异来对各种任务进行分类。同时，还列出了各任务的简称、训练和测试用图像的数量、图像尺寸以及各类别的数量。• “全球分布型数据集”指的是目标数据集具有全球范围内的分布特性。

领域 差距/ 领域 裂痕	数据 集	来源 域名	目标 域名	缩写/ 简称	列车 编号	测试 编号	图片 尺寸	类别/ 分类
未知 区域	ISPRS 波茨坦分 会， 瓦伊 欣根	波茨 坦 (IRR G)	瓦伊 欣根 (IRR G)	P(i) 2V	3456	398	{512} × {512}	6
		瓦伊 欣根 (IRR G)	波茨 坦 (IRR G)	V 2 P(i)	344	2016		6
	LoveD A [83]	Love DA- 都市 风	Love DA- 乡村 版	你还 在吗	1156	992	{1024 } × {1024 }	7
		Love DA- 乡村 版	Love DA- 都市 风	R 2 U	1366	667		7
	Deep Globe [84] 、马 萨诸 塞州	Deep Globe	马萨 诸塞 州	D 2 M	6226	49	{1024 } × {1024 }	1

	[85] (建筑物提取技术)							
	ISPRS 波茨坦分会, RescueNet [86] (灾害评估)	波茨坦 (RGB 格式)	RescueNet (RGB)	$P(r) \cdot 2 \cdot Res$	3456	449	$\{512\} \times \{512\}$	5
	LoveDA、 OpenEarthMap [87] (建筑物检测功能)	LoveDA-都市风	OpenEarthMap [^] {bullet }	U2OEM	1156	384	$\{1024\} \times \{1024\}$	6
	DeepGlobe、 GlobalRoadNet [88] (道路提取功能)	DeepGlobe	GlobalRoadNet [^] {bullet }	D2G	6226	241	$\{1024\} \times \{1024\}$	1
看不见的频谱带	ISPRS 波茨坦分会	波茨坦 (RGB 格式)	波茨坦 (IRRG)	$P(r) \times 2 \times P(i)$	3456	2016	$\{512\} \times \{512\}$	6

		波茨坦 (IRRG)	波茨坦 (RGB 格式)	$P(i) \times 2 \times P(r)$				6
不可见区域与光谱带	ISPRS 波茨坦分会, 瓦伊欣根	波茨坦 (RGB 格式)	瓦伊欣根 (IRRG)	$P(r) 2V$	3456	398	{512} × {512}	6
		瓦伊欣根 (IRRG)	波茨坦 (RGB 格式)	$V 2 P(r)$	344	2016		6
	ISPRS 波茨坦分会, RescuNet [86] (灾害评估)	波茨坦 (IRRG)	RescuNet (RGB)	$P(i) 2 Res$	3456	449	{512} × {512}	5
未知区域与平台	WHU 大楼 [89] (建筑识别)	空中卫星 II	卫星二	2S	4736	3726		1
			Aerial Satellite $\{bullet\}$	$S 2 A$	1366_2	1036	{512} × {512}	1
		空中/空中拍摄	卫星 $\{bullet\}$	A2S-I	4736	204		1

未知的区域与气候状况	CASI D [90]		温带季风气候	第 2 次 Tem		2075	{1024 } × {1024 }	5
		亚热带季风气候	热带季风气候	2 万 亿 以 下	4900	1650		5
			热带雨林	Sub 2 Trf		1550		5
			亚热带季风	第二 节		2200		5
		温带季风	热带季风气候	有 2 个 TMS 设备。	5025	1650		5
			热带雨林	有 2 个 Trf		1550		5
			亚热带季风气候	Tms 2 Sub		2200		5
		热带季风气候	温带季风气候	Tms 2 Tem	3400	2075		5
			热带雨林	Tms 2 Trf		1550		5
			亚热带季风气候	TRF 2 子版		2200		5
		热带雨林	温带季风	Trf 2 Tem	3700	2075		5
			热带季风	Trf 2 Tms		1650		5

表二

波茨坦和瓦伊兴根基准测试的性能比较。这两个 、 、 分别表示 DA 模型、RS 语义分割 VFMS 和语义分割 VFMS。加粗是最佳分数，下划线是第二。冲浪：不透水表面。BLDG：建筑。体重：植被稀少。CLUT：杂乱无章。

方法	骨干	领域		课程						mIoU (%)	领域		课程						mIoU (%)
		来源：→未见	冲浪	大楼	加权	树状结构	汽车	Clut	来源：→未见		冲浪	大楼	加权	树状结构	汽车	Clut			
DAForms*[101]	MIT-B5[102]		73.8	82.9	46.1	70.0	45.9	85.0	54.4			64.0	66.5	54.1	28.2	66.6	66.0	47.6	
HRDA*[103]	MIT-B5[102]		75.0	78.3	43.3	68.3	50.8	12.8	54.7			69.2	70.1	55.6	38.9	75.6	10.6	53.3	
S12-MoC	VIT-S[1		14.7	34.8	22.7	39.2	0.5	1.7	1.89			46.0	40.2	37.9	20.6	21.6	1.3	27.9	

o ◇ [1 0 4]	0 5]																			
S 1 2 - D I N O ◇ [1 0 4]	V i T - S [1 0 5]		1 9 . 1	3 0 . 5	2 8 . 9	2 4 . 0	4 . 5	3 . 4	1 8 . 4				3 3 . 8	3 5 . 7	3 5 . 4	2 0 . 5	1 0 . 7	1 . 5	2 2 . 9	
S 1 2 - M A E ◇ [1 0 4]	V i T - S [1 0 5]	P (i) 2 V (看不见的区域)	1 4 . 6	3 2 . 6	2 3 . 0	4 0 . 8	0 . 3	1 . 7	1 8 . 4	V 2 P (i) (看不见的区域)			4 4 . 3	4 2 . 9	4 0 . 2	2 1 . 3	1 5 . 4	2 . 7	2 7 . 8	
D O F A ◇ [1 0 0]	V i T - B [1 1 0]		3 2 . 2	4 0 . 8	3 6 . 3	3 6 . 7	5 . 2	0 . 6	2 5 . 3					4 3 . 4	3 7 . 5	3 5 . 2	2 3 . 0	2 6 . 1	2 . 1	2 7 . 9

6]	5]																	
S a t M A E ◇ [5 7]	V i T - L [1 0 5]		4 2 . 8	5 0 . 7	1 9 . 6	5 4 . 3	1 4 . 4	1 . 8	3 0 . 6			5 5 . 7	4 6 . 6	4 3 . 7	9 . 8	2 9 . 2	2 . 5	3 1 . 3
S c a l e M A E ◇ [1 0 5 7]	V i T - L [1 0 5]		4 5 . 9	6 0 . 7	3 7 . 9	5 5 . 1	9 . 1	4 . 4	3 5 . 5			5 9 . 4	5 4 . 0	4 8 . 0	8 . 1	3 9 . 9	2 . 7	3 5 . 2
远 程 C L I P ◇ [1 0 5 8]	V i T - L [1 0 5]		4 . 0	3 1 . 7	1 4 . 0	3 5 . 7	0 . 1	0 . 3	1 4 . 3			3 8 . 2	3 5 . 5	3 6 . 2	2 3 . 8	9 . 0	2 . 9	2 4 . 3

M T P ◇ [5 1]	V i T - L [1 0 5]		7 5 . 0	8 4 . 5	5 1 . 7	7 0 . 8	6 5 . 5	2 5 . 3	6 2 . 6			7 0 . 3	7 6 . 9	5 0 . 2	8 . 2	8 2 . 5	1 . 9	4 8 . 3	
干 净 ● (基 线) [9 2]	V i T - L [1 0 5]		7 9 . 4	9 0 . 4	5 4 . 0	7 1 . 5	5 3 . 6	1 3 . 0	6 0 . 3			7 5 . 9	8 6 . 5	6 0 . 6	3 7 . 9	8 0 . 6	4 . 3	5 7 . 6	
跨 地 球 (我 们 的)	V i T - L [1 0 5]		8 3 . 6	9 1 . 7	6 3 . 8	7 0 . 2	5 9 . 5	3 6 . 3	6 7 . 5 (+ 7 . 2)			7 7 . 1	8 0 . 8	6 1 . 3	3 8 . 9	8 2 . 9	8 . 4	5 8 . 2 (+ 0 . 6)	
D A F o r m s * [1 0]	M i T - B 5 [1 0 2]		8 3 . 5	8 8 . 3	6 5 . 3	7 3 . 1	9 1 . 3	3 1 . 0	7 2 . 1			8 2 . 1	9 1 . 6	6 2 . 2	7 0 . 0	9 1 . 0	2 4 . 3	7 0 . 2	

1]																		
H R D A * [1 0 3]	M i T - B 5 [1 0 2]		8 2 . 9	8 8 . 0	5 7 . 5	7 4 . 1	9 1 . 1	2 3 . 6	6 9 . 5			8 0 . 0	9 1 . 1	6 2 . 2	7 1 . 1	8 9 . 7	2 5 . 8	7 0 . 0
S 1 2 - M o C o ◇ [1 0 4]	V i T - S [1 0 5]		1 4 . 2	2 3 . 8	2 . 6	0 . 0	2 . 3	2 . 7	7 . 6			2 7 . 5	3 7 . 9	5 . 3	6 . 4	1 5 . 2	0 . 5	1 5 . 5
S 1 2 - D I N O ◇ [1 0 4]	V i T - S [1 0 5]		4 2 . 1	2 8 . 1	1 . 3	2 . 0	3 3 . 1	0 . 5	1 7 . 9			3 7 . 8	5 0 . 3	2 2 . 8	1 6 . 2	3 2 . 4	1 . 2	2 6 . 8

S 1 2 - M A E ◇ [1 0 4]	V i T - S [1 0 5]	P (r) 2 P (i) (看 不 见 的 光 谱 带)	5 6 . 3	3 0 . 5	2 . 0	1 . 3	4 9 . 5	0 . 6	2 3 . 4	P (i) 2 P (r) (未 见 光 谱 带)		2 9 . 7	4 3 . 1	1 4 . 1	9 . 4	2 . 0	0 . 6	1 6 . 5	
D O F A ◇ [1 0 6]	V i T - B [1 0 5]		5 4 . 5	3 2 . 6	1 0 . 4	6 . 0	4 3 . 3	1 . 0	2 4 . 6			4 6 . 7	4 8 . 8	3 0 . 4	1 0 . 3	4 2 . 1	1 . 1	2 9 . 9	
S a t M A E ◇ [5 7]	V i T - L [1 0 5]		5 6 . 4	4 1 . 4	2 0 . 4	2 4 . 8	5 9 . 2	8 . 9	3 5 . 2			6 3 . 1	8 1 . 5	3 7 . 2	3 1 . 0	7 5 . 4	1 0 . 4	4 9 . 8	
S c a	V i T		7 4	5 3	5 . 0	5 9	7 4	1 2	4 6			4 7	7 7	5 . 3	4 5	6 7	7 . 3	4 1	

I e M A E ◇ [1 0 7]	- L [1 0 5]		. 9	. 3		. 7	. 2	. 5	. 6			. 6	. 4		. 7	. 7		. 8	
远 程 C L I P ◇ [1 0 5 8]	V i T - L [1 0 5]		4 7 . 8	2 3 . 9	3 . 5	0 . 5	2 . 6	0 . 1	1 3 . 1			1 1 . 1	2 8 . 9	2 . 1	0 . 7	1 . 1	0 . 1	7 . 3	
M T P ◇ [5 1]	V i T - L [1 0 5]		8 3 . 4	8 1 . 3	4 2 . 2	6 8 . 0	9 1 . 3	2 0 . 6	6 4 . 5			7 8 . 6	9 1 . 3	6 2 . 5	7 1 . 3	9 1 . 0	3 1 . 2	7 1 . 0	
干 净 ● (基 线) [9]	V i T - L [1 0]		8 6 . 6	9 3 . 4	7 3 . 1	7 7 . 7	9 1 . 3	3 5 . 8	7 6 . 3			8 2 . 2	9 3 . 2	5 8 . 5	7 0 . 0	8 7 . 8	2 3 . 7	6 9 . 2	

2]	5]																	
跨 地 球 (我 们 的)	V i T - L [1 0 5]		8 6 . 1	9 1 . 5	7 3 . 8	7 9 . 7	9 1 . 9	4 3 . 8	7 7 . 8 (+ 1 . 5)			8 6 . 3	9 3 . 5	7 3 . 8	7 4 . 0	9 1 . 2	3 7 . 2	7 6 . 0 (+ 6 . 8)
D A F o r m s * [1 0 1]	M i T - B 5 [1 0 2]		6 4 . 2	7 3 . 4	4 . 5	9 . 7	4 2 . 2	1 . 5	3 2 . 6			4 6 . 0	5 9 . 4	1 2 . 6	5 . 8	6 3 . 5	2 . 9	3 1 . 7
H R D A * [1 0 3]	M i T - B 5 [1 0 2]		6 7 . 1	6 6 . 9	4 . 1	1 7 . 5	4 3 . 0	1 . 8	3 3 . 4			5 4 . 7	5 4 . 7	1 1 . 6	1 4 . 4	7 2 . 3	6 . 5	3 5 . 7
S 1 2 - M o	V i T - S [		1 1 . 5	2 5 . 2	1 . 8	0 . 0	2 . 6	1 . 7	7 . 1			4 2 . 7	2 7 . 2	4 . 3	2 . 2	2 0 . 8	1 . 2	1 6 . 4

C o ◇ [1 0 4]	1 0 5]																	
S 1 2 - D I N O ◇ [1 0 4]	V i T - S [1 0 5]		1 0 · 0	2 4 · 4	1 · 5	0 · 0	4 · 7	1 · 4	7 · 0			2 8 · 8	2 5 · 1	3 · 9	1 · 3	1 2 · 5	1 · 0	1 2 · 1
S 1 2 - M A E ◇ [1 0 4]	V i T - S [1 0 5]	P (r) 2 V (未 见 区 域 与 光 谱 带)	9 · 0	2 5 · 5	1 · 3	0 · 0	5 · 7	1 · 1	7 · 1	V 2 P (r) (未 可 见 区 域 和 光 谱 带)		4 0 · 9	2 9 · 9	9 · 1	2 · 0	2 1 · 1	1 · 4	3 3 · 7
D O F A ◇ [1]	V i T - B [1]		2 7 · 2	2 2 · 3	2 · 4	0 · 0	4 · 7	1 · 1	9 · 6			3 8 · 4	2 4 · 2	7 · 6	3 · 0	2 3 · 9	0 · 8	1 6 · 3

0 6]	0 5]																	
S a t M A E ◇ [5 7]	V i T - L [1 0 5]		5 3 · 6	2 6 · 4	3 · 5	0 · 6	2 0 · 1	8 · 2	1 8 · 7			4 5 · 0	3 8 · 0	2 0 · 9	4 · 2	2 9 · 4	2 · 4	2 3 · 3
S c a l e M A E ◇ [1 0 7]	V i T - L [1 0 5]		4 3 · 3	3 0 · 9	1 · 1	1 · 8	7 · 4	8 · 1	1 5 · 4			4 3 · 9	5 1 · 9	2 5 · 2	0 · 8	3 5 · 2	3 · 2	2 6 · 7
远 程 C L I P ◇ [1 0 8]	V i T - L [1 0 5]		4 · 0	2 3 · 2	3 · 1	0 · 0	0 · 0	0 · 1	5 · 1			3 3 · 1	2 5 · 5	2 · 1	1 · 6	6 · 9	1 · 6	1 1 · 8
M T	V i		5 1	6 4	4 ·	7 ·	5 6	1 ·	3 1			5 8	7 6	4 4	1 0	8 2	1 ·	4 8

P ◇ [5 1]	T - L [1 0 5]		.	.	4	5	.	9	.			.	.	.	.	.	4	.	
			0	8			8		1			5	5	4	8	0		6	
干 净 ● (基 线) [9 2]	V i T - L [1 0 5]																		
			7	9	3	6	6	5	5			7	7	5	1	7	4	5	
			9	1	7	2	1	7	6			0	7	8	3	8	4	0	
			.	.	.	.	.	.	.			.	.	.	.	.	.	.	
			1	2	0	2	1		1			4	4	6	9	5	4	6	
跨 地 球 (我 们 的)	V i T - L [1 0 5]								6									5	
									1									2	
									.									.	
			7	8	5	7	6	1	9			7	7	5	2	8	7	7	
			8	9	5	2	1	4	(			2	3	8	2	1	6	(	
			.	.	.	.	.	.	+			.	.	.	.	.	.	+	
			1	3	2	5	9	5	5			5	6	7	4	1		2	
									.									.	
									8									1	
									)									)	

B. 推广到看不见的区域

在本节中，区域因子是源域与未见域之间的主要差异。例如，在 $P(i)^2V$ 实验中，波茨坦的源域图像与未见的范因根图像共享相同的红外-红外-G 波段，使区域差异成为主要间隙。因此，在源域波茨坦训练的模型预计在未见的 Vaihingen 区域表现良好。该设置中使用的数据集包括 Potsdam、Vaihingen、LoveDA、DeepGlobe、Massachusetts 等。

波茨坦和瓦因根：利用 ISPRS 波茨坦和费因根数据集，我们对两项 DG 基准测试 $P(i)^2V$ 和 $V2P(i)$ 进行了实验，结果已见表二。在 $P(i)^2V$ 设定下，RS 变频器表现出较大的变异性。虽然 MTP 以 62.6% 的 mIoU 取得了最强的成绩，但 ScaleMAE (35.5%)、Sat-MAE (30.6%)、DOFA (25.3%)、RemoteCLIP (14.3%) 和 S12 变体 (18–28%) 等其他变体表现明显较差，尤其是在 Car 等小物体类别中，得分常接近零。纯正成就者 60.3%，略低于

表三

LOVEDA–农村与城市及城市与农村基准的性能比较（在官方验证集上测试）。BKGD：背景。BLDG：建筑。RD：道路。WTR：水。巴尔：酒吧。FRFIRST：森林。阿格里：农业。

模型	Bkgd	大楼	Rd	什么事	针	首先	农业	mIoU (%)
LoveDA–农村与城市表现比较								
DAForms [101]	40.1	55.2	51.7	69.9	43.3	51.9	49.0	51.6
HRDA [103]	41.6	57.1	53.1	63.2	45.6	51.8	56.0	52.6
S12-MoCo [104]	33.0	7.8	1.4	21.0	0.0	29.3	30.9	17.6
S12-DINO [104]	33.1	11.0	2.5	48.8	0.3	23.2	34.7	21.9
S12-MAE [104]	33.2	9.1	1.8	48.2	0.0	14.8	34.5	20.1
DOFA [106]	27.6	36.7	29.4	30.5	12.8	28.3	2.3	23.9
SatMAE [57]	36.5	42.3	43.7	57.1	28.5	38.6	40.5	41.0
ScaleMAE [107]	39.7	54.1	54.7	71.6	45.9	47.1	52.7	52.3
远程剪辑 [108]	24.4	3.7	0.7	12.4	0.0	19.7	26.7	12.5
MTP [51]	40.8	59.6	58.3	74.4	46.6	47.4	54.6	54.5
纯净 (基	40.3	64.0	56.6	76.0	50.4	55.4	61.1	57.7

线) [92]								
跨地 球 (我 们的)	39.8	63.3	57.3	75.9	51.8	55.0	62.5	57.9 (+0.2)
LoveDA–城市与农村的性能比较								
DAFo rms [101]	57.1	46.9	36.5	62.9	12.1	18.5	51.3	40.8
HRDA [103]	50.2	46.1	40.0	66.6	6.8	26.9	58.1	42.1
S12- MoCo [104]	42.5	14.7	16.9	11.6	7.0	1.8	0.3	23.9
S12- DINO [104]	44.8	21.0	24.9	15.8	7.0	0.8	0.3	16.8
S12- MAE [104]	42.0	17.7	7.1	11.6	7.6	4.2	0.1	12.9
DOFA [106]	27.6	36.7	29.4	30.5	12.8	28.3	2.3	13.2
SatM AE [57]	52.1	43.4	40.3	53.9	7.0	31.5	34.1	37.5
Scale MAE [107]	54.1	52.8	38.8	52.3	12.8	31.0	42.2	40.6
远程 剪辑 [108]	40.7	13.4	9.5	5.2	3.4	1.5	0.0	10.5
MTP [51]	55.5	44.4	46.3	66.7	7.3	37.0	50.7	44.0
纯净 (基	57.0	56.3	49.4	68.2	9.3	25.5	53.5	45.6

线) [92]								
跨地 球 (我 们的)	57.5	61.5	48.5	65.6	9.6	25.4	58.2	46.6 (+1.0)
LoveDA–Urban 与 OpenEarthMap 的性能比较								
DAFo rms [101]	47.7	58.6	31.3	31.2	2.9	45.2	34.9	36.0
HRDA [103]	46.1	53.3	37.1	32.5	1.5	35.1	41.9	35.4
S12- MoCo [104]	36.9	26.7	13.3	9.9	3.3	9.8	1.3	14.5
S12- DINO [104]	36.4	31.5	14.7	17.9	2.5	7.4	0.4	15.8
S12- MAE [104]	36.1	27.4	10.8	20.7	2.6	10.3	0.4	15.4
DOFA [106]	35.2	32.7	14.2	24.8	3.8	8.2	1.9	17.3
SatM AE [57]	38.7	43.4	23.0	25.1	6.4	10.0	10.7	23.7
Scale MAE [107]	40.5	44.6	31.6	21.3	0.7	28.1	15.5	26.0
远程 剪辑 [108]	40.2	9.9	7.0	5.2	2.3	8.6	0.0	10.5
MTP [51]	40.2	57.8	36.4	55.4	2.7	46.2	38.0	39.5
纯净 (基	45.2	63.4	38.1	62.7	4.2	42.5	65.2	45.9

线) [92]								
跨地 球 (我 们的)	47.6	65.1	39.9	69.9	13.2	42.4	66.3	49.2 (+3.3)

MTP，很可能是因为它的自然影像来源。相比之下，CrossEarth 整体表现最佳，达到 67.5%，比 Rein 高+7.2%，MTP 高+4.9%，在广泛类别（坚水面、低植被）以及挑战性类别如杂乱中均有优势。

在 V2P (i) 基准测试上，观察到类似趋势。Scale-MAE (35.2% mIoU)、SatMAE (31.3%) 和 DOFA (27.9%) 仍有限，而 MTP 在 RS VFM 中表现最佳，达到 48.3%。莱因是 57.6%的强劲基础，尤其在建筑班表现出色。CrossEarth 建立了新的 SOTA，mIoU 为 58.2%，比 Rein 高+0.6%，并在大面积和小天体类别中保持稳定增益，展现出更强的稳健性和泛化性。

LoveDA（农村与城市）：除了不同城市，我们还考虑了另一种区域跨域差距，体现在城市和农村景观上。为此，我们使用 LoveDA 数据集，并在两个基准测试上进行实验：农村到城市（R2U）和城市到农村（U2R），结果见表 III。

在 R2U 设置下，DAFormer 和 HRDA 等专业 DA 模型可实现中等性能（约 52–53% mIoU）。在 RS VFM 中，大多数方法，包括 S12-MoCo/DINO/MAE 和 RemoteCLIP，都难以适应，常在 Road 和 Barren 等类别中失败。SatMAE 和

表四

基于 MIOU 分数（%）的建筑采掘和道路采掘任务性能比较，跨越 A2S、A2S-I、S2A、D2M 和 D2G 基准测试

模型	建筑			公路	
	A2S	A2S-I	S2A	D2M	D2G
DAForms [101]	7.1	0.6	64.3	41.9	18.3
HRDA [103]	7.9	4.9	62.7	50.3	20.1
S12-MoCo [104]	7.7	20.1	20.9	7.8	11.2
S12-DINO [104]	6.8	17.1	19.9	5.9	9.3

S12-MAE [104]	5.4	22.3	19.3	7.1	11.5
DOFA [106]	5.7	23.9	19.6	8.4	12.2
SatMAE [57]	12.9	32.8	18.1	23.3	20.2
ScaleMAE [107]	0.6	38.0	19.4	32.1	23.4
远程剪辑 [108]	4.8	20.9	18.0	5.9	6.8
MTP [51]	23.6	46.0	47.2	54.3	22.6
纯净（基线） [92]	30.8	48.0	66.8	49.7	23.0
跨地球（我们的）	44.3 (+13.5)	57.1 (+9.1)	64.5 (-2.3)	50.5 (+0.8)	24.2 (+1.2)

ScaleMAE 在主导类别表现相对较好（例如水资源类别中达到 71.6%），但整体表现有限。在 RS VFM 系列中，MTP 表现最优，在公路组表现出色（58.3%），而 Rein 虽然最初基于自然影像预训练，但在建筑（64.0%）和农业（61.1%）方面表现出色，整体表现具有竞争力。在 U2R 基准测试上，出现了类似的趋势。大多数 RS VFM 再次显示出有限的效果，尤其是在农业主导的类别上。尽管 ScaleMAE 和 SatMAE 依然更具竞争力，但仍不及 MTP 和 Rein。CrossEarth 在两个基准测试中均实现了 SOTA 表现，mIoU 分别提升了 0.2%和 1.0%，相较于基准 Rein。值得注意的是，在 U2R 任务中，建筑（+5.2%）和农业（+4.7%）的增长最大，尽管这些类别在城乡景观中存在显著视觉差异（见补充资料中的图片），显示了 CrossEarth 在弥合这些差距方面的有效性。

道路检测（DeepGlobe 和马萨诸塞州）：RS 道路检测对于推进交通基础设施和维护最新地图数据至关重要。然而，不同地理位置道路的环境复杂性使得在多元区域有效应用单一模型变得困难，导致数据收集和模型训练成本高昂。为了评估跨区域道路检测性能，我们使用 DeepGlobe 和马萨诸塞州数据集，在 DeepGlobe 数据集上训练，在马萨诸塞州测试集（D2M）上进行测试，结果已见表 IV。

在 D2M 基准测试中，DAFormer 和 HRDA 等 DA 模型取得了中等成绩（41.9%—50.3% mIoU），HRDA 表现更好。RS 特有的 VFMs，包括 S12-MoCo、S12-DINO、S12-MAE、DOFA 和 RemoteCLIP 表现非常差（<10%），表明单靠预训练无法有效转移至道路撤离。SatMAE（23.3%）和 ScaleMAE（32.1%）在一定程度上缓解了这一问题，但仍未达到更强的基线。在 RS VFM 中，MTP 表现最佳（54.3%），展现了对道路薄长结构的强烈适应能力。相比之下，通用 VFMRain 的表现也具竞争力（49.7%），超过了大多数专用的 RS 型 VFM。我们的

表 V

P (R) 2RES 和 P (I) 2RES 基准测试的性能比较。灰色方块突出了 CROSSEARTH 相较其他方法的显著改进。冲浪：不透水表面。BLDG：建筑。CLUT：杂乱无章。

方法	骨干	领域		课程				mIoU (%)	领域		课程				mIoU (%)
		来源： → 未见	冲浪	大楼	树状结构	汽车	Cut		来源： → 未见	冲浪	大楼	树状结构	汽车	Cut	
RescueNet 基准测试跨域泛化设置的性能比较															
DeepLabv3+ [112]	ResNet-101 [113]		26.9	23.3	1.3	2.5	53.3	21.5		12.8	9.7	40.4	9.4	17.6	18.0
DAFormer [101]	MIT-B5 [102]		33.0	32.6	55.0	7.6	66.7	39.0		34.1	43.6	41.7	12.0	58.9	38.1
HRDA [1	MIT-B5 [		28.8	27.2	56.8	4.0	66.4	36.6		26.1	29.2	44.3	5.2	61.6	33.3

0 3]	1 0 2]														
S 1 2 - M o C o [1 0 4]	V iT - S [1 0 5]		7 . 8	9 . 4	5 . 0	1 . 5	0 . 6	4 . 9		2 . 9	9 . 1	2 . 1	1 . 1	0 . 3	3 . 1
S 1 2 - D I N O [1 0 4]	V iT - S [1 0 5]	P (r) 2 R e s	6 . 8	9 . 8	1 8 . 8	1 . 0	0 . 2	7 . 3	P (i) 2 R e s	0 . 8	1 0 . 2	2 2 . 2	2 . 1	1 . 4	7 . 3
S 1 2 - M A E [1 0 4]	V iT - S [1 0 5]		2 . 5	9 . 3	6 . 8	0 . 4	0 . 2	3 . 8		5 . 6	1 0 . 1	1 0 . 3	2 . 5	0 . 9	5 . 9

D O F A [1 0 6]	V i T - B [1 0 5]	(未 见 的 区 域)	5 . 0	9 . 0	3 . 5	1 . 3	0 . 3	3 . 8	(看 不 见 区 域 与 光 谱 带)	2 . 6	8 . 9	0 . 8	1 . 0	0 . 6	2 . 8
S a t M A E [5 7]	V i T - L [1 0 5]		1 3 . 7	1 3 . 8	2 6 . 1	3 . 7	2 7 . 1	1 6 . 9		1 5 . 5	1 3 . 7	2 4 . 4	3 . 0	2 1 . 1	1 5 . 5
S c a l e M A E [1 0 7]	V i T - L [1 0 5]		2 3 . 5	3 1 . 9	4 5 . 4	0 . 1	4 7 . 7	2 9 . 7		1 3 . 9	3 5 . 0	4 8 . 7	0 . 3	4 9 . 4	2 9 . 4
远 程 剪 辑 [1 0 8]	V i T - L [1 0 5]		2 . 2	8 . 2	2 . 6	0 . 0	0 . 0	2 . 6		1 . 3	1 0 . 1	2 7 . 5	0 . 2	0 . 8	8 . 0

MTP [51]	VIT - L [105]		34.3	40.9	41.7	16.3	62.7	39.2		31.3	36.8	0.5	14.4	57.5	28.1
纯净 (基线) [92]	VIT - L [105]		53.6	49.5	44.2	13.7	68.6	45.9		51.3	47.3	48.5	13.3	66.5	45.4
跨地球 (我们的)	VIT - L [105]		43.6	59.7 (+10.2)	51.0	16.4	63.2	46.8 (+0.9)		41.9	60.6 (+13.3)	51.3	10.6	62.9	45.5 (+0.1)

CrossEarth 达到 50.5%，略高于 Rein (+0.8%) 和 HRDA，但仍低于 MTP。我们认为这一空白可能与骨干网络的结构有关，并在补充材料中提供进一步讨论。

灾害评估 (Potsdam 和 RescueNet)：鉴于灾害的不确定性，采用能够在不同地区快速部署且无需额外培训时间或数据成本的模型至关重要，凸显了 RSDG 的重要性。这种应急能力对于灾后任务至关重要，比如估算损失程度和规划救援路线，尤其是在灾害频繁的年份。为评估该能力，我们构建了两个相关的基准测试：P (r) 2Res 和 P (i) 2Res。对于未见区域的间隙，我们首先讨论 P (r) 2Res，如表 V 所示。

在 P (r) 2Res 基准测试中，CrossEarth 在 Building 级表现尤为突出，实现了 59.7%的 mIoU，远远超过 Rein，达到+10.2%。与其他 VFM 相比，差距更为明显：如 S12-MoCo、DOFA 和 RemoteCLIP 等 RS 专用型号无法推广到这一类别，通常低于 10% mIoU。更先进

的 RS VFM 如 SatMAE、ScaleMAE 和 MTP 提供了改进（分别为 13.8%、32.9%和 40.9%），但仍远未达到可靠的灾害相关建筑分段。

我们将此归因于：(1) 多任务学习的地球式注入技术使跨域表示提取更强，使模型能够捕捉灾后条件下建筑的结构和语义变化；(2) 数据集特性——RescueNet 强调建筑损坏评估，采样大量图像使建筑物占据主导场景，使该课程尤为关键；(3) DINOv2 的以对象为中心的偏向，这与 RescueNet 以建筑为中心的特性相符。这些因素共同解释了 CrossEarth 为何在建筑方面取得如此显著的收益，凸显了其在灾后评估中具有实用价值，尤其是在准确的建筑分段至关重要时。

全局推广：如表 III 所示，在最初的 LoveDA 实验中，CrossEarth 相较于 Rein 的改进相对有限。为了进一步评估泛化性，我们将 OpenEarthMap 标签映射到 LoveDA 数据集，并直接评估 OpenEarthMap 验证集上的 Urban–Rural 训练权重。在全球分布的场景中，

CrossEarth 展现了更强的推广能力，实现了 49.2%的 mIoU，超过了 Rein (45.9%，+3.3%)，并且比 MTP 高出近 10%。相比之下，大多数其他模型性能崩溃，表明 LoveDA 的适度提升主要与数据集约束有关，而 CrossEarth 在全球评估中展现了其真实能力。在 GlobalRoadNet 数据集 (D2G) 上的道路提取中，如表 IV 所示，CrossEarth 同样取得了最佳成绩，比 Rein 高出+1.2%。这与表 III 中的趋势一致，CrossEarth 在全球基准测试中展现出更强的优势。图 6 提供了更多定性结果。

这些结果共同验证了 CrossEarth 的有效性，并明确展示了其在全球分布场景下的跨域推广优势。

C. 推广到未见光谱带

与未可见区域的挑战类似，本节实验主要评估模型推广至未可见光谱带的能力。在这里，我们仍然使用 ISPRS 的 Potsdam 和 Vaihingen 数据集，并构建跨不同渠道的 P (i) 2P (r) 和 P (r) 2P (i) 基准测试。

波茨坦和费兴根：如表二所示，在 P (r) 2P (i) 基准测试中，CrossEarth 实现了 77.8%的 mIoU，超过了 Rein (+1.5%) 和 MTP (+13.3%)，而其他 RS 特有的 VFMs，如 SatMAE (35.2%) 和 ScaleMAE (46.6%)，在频谱偏移下表现远不如前。Rein 的骨干以自然 RGB 图像预训练，但训练于红外–R–G 输入时性能下降，仅达到 69.2%的 mIoU。在反向 P (i) 2P (r) 设置下，CrossEarth 再次以 76.0% mIoU 领先，领先 Rein+6.8%，远高于所有其他 VFMs。这些结果表明，传统的 RS VFM 在处理未见光谱带时遇到困难，而 CrossEarth 则有效弥合了这些差距，并在双向保持顶尖性能。

D. 推广至未见区域和光谱带

本设置旨在同时考察模型在不同区域和光谱带上的泛化性。与上述实验相比，该任务更为困难，且对模型能力的要求更高。

图 5。波茨坦和瓦兴根基准测试预测分段图的可视化。关于颜色地图，白色是坚不可摧的表面类别，红色是杂乱类，蓝色是建筑类，青色是低植被类，绿色是树木类，黄色是汽车类。

图 6。道路检测和建筑提取在全球泛化下的分段图可视化。

Potsdam 和 Vaihingen：我们还利用这些数据集构建了两个额外的基准测试：P (r) 2 V 和 V2P (r)。如表二所示，模型性能相较于 P (i) 2 V 和 V2P (i) 设置的准确性明显下降。DAFormer、HRDA 和 MTP 均遭遇严重性能下降，mIoU 在从 P (i) 2 伏切换到 P (r) 2 伏时下降超过 20%。同样，RS 视频如 SatMAE 和 ScaleMAE 仍远低于 40%，凸显了适应联合区域和频谱频段移的特殊挑战。相比之下，CrossEarth 的设计融合了 RS 知识学习和跨域泛化。因此，CrossEarth 在 P (r) 2 V 上以 61.9% 的 mIoU 和 V2P (r) 上的 52.7% mIoU 表现最佳，分别比 Rein 高出 5.8% mIoU 和 2.1% mIoU。

我们还在图 5 中展示了定性结果。由于该环境的复杂性，模型预测与真实标签之间存在明显差异。在 P (r) 2 V 基准测试中，几乎所有模型都倾向于受杂波类影响。对于 DAFormer 和 HRDA 来说，这种影响尤为严重，影响建筑和植被低矮类别。使用 VFM 如 MTP 和 Rein 时，这种干扰在一定程度上得到缓解。值得注意的是，CrossEarth 显著减少了这种错误分类，市场错误分类的红色区域数量有所减少。

灾难评估 (Potsdam 和 RescueNet)：在 P (i) 2Res 基准 (表 V) 中，CrossEarth 整体表现最佳，表现为 45.5% mIoU，略高于 Rein (+0.1%)。最显著的提升体现在建筑级别，CrossEarth 获得了 60.6%，比 Rein 取得了+13.3%的显著提升。相比之下，RS 专用 VFM 如 S12-MoCo 和 RemoteCLIP 的崩溃率低于 11%，而更先进的型号如 SatMAE (13.7%) 和 ScaleMAE (35.0%) 也远低于此。尽管 MTP 提升至 36.8%，但仍明显落后于 CrossEarth。这些结果展示了 CrossEarth 在灾害相关建筑分割中的稳健性，即使在未知区域和频谱变化的双重挑战下依然如此。

E. 推广到看不见的区域和平台

我们还进一步考虑了不同数据采集平台带来的差异。RS 影像通常可分为两类：卫星影像和航拍影像。来自不同来源的图像在分辨率、物体比例和覆盖范围上存在显著的领域差距。卫星图像通常分辨率低于航空图像，非常适合大规模监测，而航空图像则适合捕捉详细的土地覆盖信息。

表 VI

CASID 基准测试的性能比较。比较包括 4 个领域内实验和 12 个域外实验，涵盖不同专业模型和 VFM。子弹：亚热带季风。主题：温带季风。TMS：热带季风。TRF：热带雨林。

方法	骨干	领域 (来源→未见) — mIoU (%)							
		字幕 (仅源代码)	Sub2 Tem (子 2Tem)	Sub2 Tms	亚 2Trf	Tem (仅源代码)	泰姆 2 字幕	Tem 2Tms	Tem 2Trf

Dee pLab v2 [114]	ResN et- 101 [113]	60.9	10.0	12.8	15.3	39.9	9.4	10.9	12.2
DAF orme r [101]	MiT- B5 [102]	68.0	36.0	63.5	59.0	45.0	59.8	63.8	51.7
HRD A [103]	MiT- B5 [102]	66.3	34.6	63.0	56.2	46.3	62.7	63.3	44.9
S12- MoC o [104]	ViT- S [105]	40.3	19.6	29.3	32.1	18.3	21.5	17.1	12.2
S12- DIN O [104]	ViT- S [105]	27.6	18.7	21.3	26.2	22.4	28.1	21.9	24.7
S12- MAE [104]	ViT- S [105]	28.2	18.2	19.9	26.3	21.2	25.4	22.4	24.9
DOF A [106]	ViT- B [105]	33.6	18.5	25.3	30.1	21.2	26.4	22.9	20.8
SatM AE [57]	ViT- L [105]	60.8	33.1	52.9	48.7	36.2	51.8	43.7	36.2
Scal eMA E	ViT- L	66.3	39.2	60.7	56.4	50.4	62.5	57.3	45.9

[107]	[105]								
RemoteCLIP [108]	ViT-L [105]	16.6	8.5	15.1	19.7	18.0	54.3	57.8	16.7
MTP [51]	ViT-L [105]	68.0	39.4	60.0	61.6	42.9	66.2	64.7	48.3
Rein (基准值) [92]	ViT-L [105]	67.2	46.4	59.7	63.4	51.3	65.5	62.9	55.9
CrossEarth (我们的)	ViT-L [105]	69.4 (+2.2)	48.1 (+1.7)	64.6 (+4.9)	64.2 (+0.8)	53.5 (+2.2)	63.5 (-2.0)	61.8 (-1.1)	57.8 (+1.9)
方法/方式	骨干/核心部分	领域（从“已查看”状态转为“未查看”状态）——mIoU(%)							
		Tms (仅源代码)	Tms 2Sub	Tms 2Tem	Tms 2Trf	Trf (仅源文件)	Trf2 Sub	Trf2 Tem	Trf2 Tms
DeepLabv2 [114]	ResNet-101 [113]	56.5	12.8	12.2	9.1	49.0	10.2	8.5	10.9
DAFormer [101]	MiT-B5 [102]	64.1	61.8	31.4	56.2	64.6	62.9	39.6	62.7
HRDA	MiT-B5	62.6	63.8	33.3	56.9	63.5	63.3	43.0	63.1

[103]	[102]								
S12-MoC o [104]	ViT-S [105]	21.1	28.8	21.6	27.3	28.9	33.0	18.7	26.3
S12-DIN O [104]	ViT-S [105]	17.5	22.9	18.0	23.0	31.5	35.0	17.3	21.5
S12-MAE [104]	ViT-S [105]	17.5	26.6	18.9	27.6	32.5	34.0	14.5	19.5
DOF A [106]	ViT-B [105]	24.1	29.8	18.8	29.1	31.2	36.1	17.1	35.7
SatM AE [57]	ViT-L [105]	57.4	60.2	32.5	53.0	57.8	59.1	32.8	56.7
Scal eMA E [107]	ViT-L [105]	61.1	62.1	35.2	55.4	59.5	60.6	30.9	58.0
Rem oteC LIP [108]	ViT-L [105]	18.7	22.5	12.3	22.5	26.4	32.1	26.0	23.6
MTP [51]	ViT-L [105]	62.5	56.1	32.3	60.1	62.8	55.6	37.0	59.8

Rein (基准值) [92]	ViT-L [105]	65.0	68.6	37.2	59.7	61.0	67.6	37.8	64.9
CrossEarth (我们的)	ViT-L [105]	68.9 (+3.9)	69.1 (+0.5)	40.5 (+3.3)	60.7 (+1.0)	65.3 (+4.3)	67.9 (+0.3)	42.3 (+4.5)	64.4 (-0.5)

WHU 大楼数据集：为探讨上述问题，我们使用了广为人知的 WHU 大楼数据集，对比了 WHU-Aerial 图像与 WHU-Satellite 图像之间的差异。由此产生了两种处理方式：从航空图像到卫星图像的处理方式（A2S），以及从卫星图像到航空图像的处理方式（S2A）。如表 IV 所示，A2S 处理方式难度极大。诸如 DAFormer 和 HRDA 之类的深度学习模型，其 mIoU 值均低于 8%；而包括 SatMAE、ScaleMAE 和 RemoteCLIP 在内的遥感验证模型也难以取得理想效果，其 mIoU 值大多低于 15%。即便是像 MTP 这样性能较强的遥感验证模型，其 mIoU 值也只有 23.6%；而在所有基准模型中表现最好的 Rein，其 mIoU 值仅为 30.8%。这些结果表明，基于高分辨率航空图像训练的模型很难有效地泛化到卫星图像上，这进一步体现了跨平台数据迁移中的不对称性。相比之下，S2A 处理方式的性能要好得多，大多数模型的 mIoU 值都明显更高。这种不对称性可能源于以下原因：卫星图像所包含的物体信息较为零散且抽象，因此难以被有效利用。不过，CrossEarth 成功弥补了这一缺陷，其 mIoU 值比 Rein 高出 13.5%（从 30.8% 上升至 44.3%）。我们认为，这一提升得益于 CrossEarth 的地理空间设计能力，该设计使其能够准确捕捉到遥感图像中的建筑物分布和结构信息，从而有助于在分辨率较低、语义较为抽象的情境下实现良好的泛化能力。关于 CrossEarth 在 S2A 基准测试中的表现不佳的问题，我们将在补充材料中进一步分析。

全球泛化能力：表 IV 进一步展示了在全局范围内进行建筑信息提取的结果。具体来说，是针对全球范围内分布的 WHU 建筑进行的分析。

在“空对星-I”基准测试中，CrossEarth 的表现比基准值高出 9.1%，这一成绩充分体现了其在全球范围内进行泛化处理的强大能力。我们在图 6 中还提供了模型预测结果的可视化展示。这些结果进一步表明，与其他模型相比，CrossEarth 在建筑物识别方面具有更出色的视觉效果，同时也展现了更强的跨领域适应能力。

F. 对未见区域和气候情况的推广应用

最后但同样重要的是，我们还考虑了一个常被 RS 图像分析领域所忽视的因素：气候。我们认为，无论是 DA 还是 DG，其目标都是构建出一个能够在不同领域中都具有良好泛化能力的统一模型。如果我们希望开发出能够适用于地球上任何地区的模型，那么气候就是一个至关重要的因素。不同的气候条件会带来各种显著差异：比如，受文化和居住条件影响而产生的不同建筑密度；由于温度和湿度差异而导致的不同植物分布；以及与干旱程度相关的不同水

域面积。因此，气候为跨领域语义分割研究提供了重要的研究方向，不过目前很少有方法真正关注这一因素。

考虑到这些问题，我们利用 CASID 数据集[87]构建了 DG 基准测试。如表 VI 所示，我们进行了 12 次跨领域实验和 4 次同领域实验。首先来看同领域实验：训练和测试都在同一领域内进行。在监督学习环境下，DAFormer 和 HRDA 都取得了不错的成绩。然而，在大多数跨领域实验中，包括 Sub2Tem、Sub2Trf 和 Tms2Trf，它们的性能大幅下降，这说明它们的泛化能力有限。在 DG 任务中，各种 RS VFMs 之间的差距更加明显：许多模型的性能甚至降到了不可用的水平。

MTP

CrossEarth

DAFormer

图片/图像

HRDA

DOFA

ScaleMAE

SatMAE

GT 标签

莱因

图 7. 在 CASID 基准测试中，DA 模型和 VFMs 所预测的分割结果的可视化结果。其中，红色代表道路类别，黄色代表建筑物类别，蓝色代表水域类别，绿色代表森林类别，黑色则代表背景类别。

30%的 mIoU 值，而 SatMAE 和 ScaleMAE 虽然表现更好（33.1–62.5%），但仍无法与 Rein 这样的优秀基准模型相媲美。尽管 MTP 和 Rein 的泛化能力更稳定，但它们也未能始终优于基于深度学习的模型。这一结果再次凸显了由于气候和地区差异所带来的挑战。

相比之下，CrossEarth 在大多数基准测试中都取得了最先进的性能表现。它在同一数据集上的测试结果优于 DA 模型和现有的 VFMs；在数据集发生变化时，其准确率依然保持竞争力。在 Sub2Tms 测试中，CrossEarth 的 mIoU 比 Rein 高出 4.9%；在 Tms2Tem 测试中则高出 3.3%。这些结果表明了 CrossEarth 出色的分割能力和良好的泛化能力。

除了定量实验之外，我们在图 7 中还展示了预测得到的分割结果。在 Sub2Tem 测试环境中，CrossEarth 在识别森林区域方面表现得优于其他模型，这一结果与表 VI 中的数据一致。总体而言，这些可视化预测结果有助于直观地理解各项定性分析结果。基于这些实验结果，我们可以得出结论：虽然 CrossEarth 在弥补不同气候数据之间的差异方面比现有模型更有效，但在跨气候研究领域仍存在许多需要解决的挑战。

G. 消融研究

正如表 VII 所示，我们对 CASID 进行了消融研究，得到了以下研究结果。

各主要组件的有效性 (R1–R8)：每个模块都能带来不同的优势。GSE (R2) 在特定领域的数据集上表现优异，但在跨领域测试中的效果则相对有限。相比之下，MIM (R3) 和 Style Injection (R4) 在跨领域任务中表现更好，有助于提升模型的泛化能力。将它们结合起来使用 (R5–R7) 能进一步提升性能，而完整的 CrossEarth 系统 (R8) 则取得了最佳的整体效果，这进一步证明了各组件之间的互补性。

(a) 波茨坦 (IRRG) 和瓦伊欣根

(b) 波茨坦 (RGB 格式) 和瓦伊欣根

图 8. 该区域的 UMAP 可视化结果以及各光谱带之间的能隙情况。不同颜色的点代表了来自不同区域的特征图像素分布。绿色圆圈标出了那些分布较为接近的区域，说明这些区域的能隙较小。相反，红色圆圈则标出了那些分布差异较大的区域，意味着这些区域的能隙较大。

在 Injector (R9) 中，我们比较了采用简单线性投影方式实现的版本与采用交叉注意力机制的版本。结果表明，两种方式都优于基准模型，但交叉注意力机制的整体性能更佳。这说明交叉注意力机制能够更有效地实现特征之间的交互，也能更出色地将地理空间查询信息与模型中的其他特征相结合。因此，交叉注意力机制确实是 Injector 的更佳选择。

样本门概率 p 的影响 (R11–R14)：我们研究了不同的注入概率 p 对系统性能的影响。当风格化样本的比例较小时（例如 $p = 0.1$ ），系统性能最佳；而当这一比例增大时，系统的准确性会逐渐下降。当比例过大时（ $p = 0.9$ ），系统的性能会明显恶化。这说明，适量的风格化数据有助于提升数据的多样性并改善模型的泛化能力；而过多的风格化样本则会影响训练数据的分布，从而限制模型对原始数据特征的捕捉能力。

(a) 波茨坦 (RGB 格式) 和瓦伊欣根

表七

针对 CASID 数据集进行了全面的消融实验研究。所有模型都在具有相同预算的子模型上进行了训练，并在 SUBMS/TEMMS/TRMS/TRORF 数据集上进行了评估，评估指标为 MIOU 百分比。其中，CA 表示交叉注意力机制；MIM DEC.指的是 MIM 模型的解码器；STYLE 则指的是“地球风格”注入模块。所有方法的训练参数都是固定的：迭代次数为 30K 次，批量大小为 1，优化器为 ADAMW，初始学习率为 1×10^{-5} 。在生成掩码时，经过“地球风格”处理的图像使用掩码比例 $\tau_m = 0.1$ ，块大小为 $B=64$ ；而未被处理的图像则使用掩码比例 $\tau_m = 0.7$ ，块大小同样为 $B=64$ 。值得注意的是，CASID 数据集上采用了 L_{MIM} 作为损失函数，同时配合 ℓ_1 进行训练。SUBMS：亚热带季风区。TEMMS：温带季风区。TROMS：热带季风区。TRORF：热带雨林地区。

设置		GS Ef _G	Inj ect orf _I	MI M de c.f _A	L_ {M IM }	L_ Δ	p	提交结果——mIoU 百分比				
								提交	泰 姆 斯	特 罗 姆 斯	特 罗 夫	平 均 值
▼ 各主要组成部分的效力（GSE、MIM、Style）												
R1	基 准 值 / 初 始 状 态	-	-	-	-	-	-	67 .2	46 .4	59 .7	63 .4	59 .2
R2	R1 +G SE	√	CA	-	-	-	-	69 .0	46 .1	60 .2	62 .8	59 .6 (+ 0. 4)
R3	R1 + MI M	-	-	AS PP	\ell _1	-	-	68 .7	47 .2	62 .7	63 .1	60 .4 (+ 1. 2)
R4	R1 + 风 格	-	-	-	-	-	0. 1	68 .4	45 .6	61 .5	63 .7	59 .8 (+ 0. 6)
R5	R2 + MI M	√	CA	AS PP	\ell _1	-	-	69 .6	47 .4	63 .5	63 .2	60 .9 (+ 1. 7)
R6	R2 + 风 格	√	CA	-	-	-	0. 1	69 .3	46 .9	63 .3	62 .2	60 .4 (+ 1. 2)

R7	R3 + 风格	-	-	AS PP	\ell _1	\ell _1	0. 1	69 .1	47 .8	64 .0	64 .2	61 .3 (+ 2. 1)
R8	R6 + MIM (Cr os sE art h)	√	CA	AS PP	\ell _1	\ell _1	0. 1	69 .4	48 .1	64 .6	64 .2	61 .6 (+ 2. 4)
▼ 注射器的切除/拆除												
R9	R8 (f _l= FF N)	√	FF N	AS PP	\ell _1	\ell _1	0. 1	68 .9	47 .8	63 .9	64 .0	61 .2 (+ 2. 0)
▼ MIM 中解码器的消除/去除												
R1 0	R8 (f _A = 线 性)	√	CA	线 性 的	\ell _1	\ell _1	0. 1	65 .1	49 .1	57 .6	64 .4	59 .1 (-0 .1)
▼ 在 Style 模型中消除损失函数和样本门的作用												
R1 1	R8 (p= 0. 3)	√	CA	AS PP	\ell _1	\ell _1	0. 3	69 .0	47 .5	63 .8	63 .5	60 .9 (+ 1. 7)
R1 2	R8 (p=	√	CA	AS PP	\ell _1	\ell _1	0. 5	68 .6	47 .0	63 .2	62 .9	60 .4 (+

	0.5)											1.2)
R13	R8 (p=0.7)	√	CA	ASPP	\ell_1	\ell_1	0.7	67.9	46.3	62.5	62.4	59.8 (+0.6)
R14	R8 (p=0.9)	√	CA	ASPP	\ell_1	\ell_1	0.9	67.0	45.9	60.8	61.0	58.7 (-0.5)
R15	R8 (\ell_{mask}=\ell_2)	√	CA	ASPP	\ell_2	\ell_1	0.1	67.3	46.8	62.0	62.9	59.8 (+0.6)
R16	R8 (\ell_{Delta}=\ell_2)	√	CA	ASPP	\ell_1	\ell_2	0.1	68.7	47.2	63.3	62.9	60.5 (+1.3)

(b) 波茨坦 (IRRG) 和瓦伊欣根

图 9. 不同领域特征之间的聚类结果。圆点和星号分别代表两个不同的领域。在颜色标注方面：紫色代表背景类别，青色代表建筑物类别，深绿色代表低矮植被类别，浅绿色代表树木类别，黄色代表汽车类别，红色代表其他杂物类别。橙色圆圈标出了两个领域特征高度相似的区域；黑色圆圈则标出了低矮植被和树木类别容易被误识别的区域。

MIM 的损失函数设计 (R15–R16)：我们比较了 MIM 中 ℓ_1 和 ℓ_2 这两种损失函数的表现。虽然 ℓ_2 能带来一定的改进，但总体而言其效果不如 ℓ_1 。其中一个可能的原因是

CASID 的特性：在图像中，背景或杂散像素占主导地位（通常超过 85%）。在这种不平衡的情况下， ℓ_1 能更有效地惩罚前景区域的错误，从而有助于提高重建结果的稳定性。因此，我们的最终设计方案（R8）采用了 ℓ_1 作为两种损失函数。

H. 可视化展示

领域差异：在第五-D 节中，我们比较了 P(r)2 V 与 P(i)2 V 的性能表现，认为性能下降是由于各种领域差异共同作用的结果。为了验证这一假设，我们利用 UMAP 技术[112]来更直观地展示这些领域差异。如图 8 所示，这些特征是从主干网络的最后一层提取的。从图中可以看出，Potsdam (RGB) 与 Vaihingen 之间、以及 Potsdam (IRRG) 与 RescueNet 之间的领域差异较大。这表明，较大的领域差异很可能是由光谱波段上的差异所导致的。这些观察结果与表 II 和表 V 中的性能数据一致：较小的领域差异有助于模型更好地进行泛化，从而提高准确率；而较大的领域差异则会给模型的适配带来更大挑战。此外，本节分析还进一步验证了各项基准测试设置背后的合理性。

CrossEarth 的代表性能力：在图 9 中，我们同样采用了 UMAP 技术来降低从两个不同领域中提取的特征的维度。这两个领域分别用点和星形来表示。从橙色圆圈中可以看出，CrossEarth 为同一类别在不同领域中提取的特征能够紧密地聚集在一起，从而在特征空间中形成清晰的群体。尽管存在领域差异，但每个类别的特征仍然保持着很强的关联性，这体现了 CrossEarth 能够学习到具有鲁棒性、不受领域影响的特征。除了具备领域不变性之外，这些特征还能有效地区分不同类别，每个类别都形成了独立的群体。

图 10. CrossEarth 在不同基准实验中提取出的特征可视化结果。

这种较高的类别间可区分性体现了 CrossEarth 出色的表征能力，它能够有效地区分不同类别之间的明显界限。另一个值得注意的现象是：低植被类和树木类之间存在轻微的重叠，这一点可以从黑色圆圈中看出来。鉴于这些类别之间的自然相似性，这种轻微的重叠是可以理解的。这也表明，该模型在表征学习过程中能够准确捕捉各种特征的实际情况。虽然 CrossEarth 在区分不同类别方面表现出色，但这种轻微的重叠也反映出：在完全区分那些高度相似的类别时，确实存在一定的挑战，尤其是在 RSDG 场景中。其他数据集的可视化结果则包含在补充材料中。

地理空间特征：在图 10 中，我们展示了基于 ISPRS 和 CASID 数据集的 CrossEarth 模型在各项测试任务上的特征图。这些特征是从主干网络的最后一层提取出来的。需要指出的是，这些可视化结果实际上属于特征图，而非热力图。因此，我们主要关注特征图中的语义边界，而非颜色的深浅。

可以看出，在 P(i)2 V 中，尽管在模型训练时使用的是 RGB 图像，但建筑物周围仍然是“红色”的树木。不过，从特征图中可以清晰地看出建筑物和树木之间的区别。在 V2P(r)和 V2P(i)中，特征图能够准确描绘出建筑物的轮廓和内部结构。此外，在 CASID 实验中，虽然低分辨率卫星图像中包含各种复杂的物体和道路网络，但特征图仍然能够准确捕捉道路的信息——红色区域清晰地标出了道路的走向。这些特征图还帮助我们详细了解背景元素：蓝色区域则清晰地标出了地形的轮廓。值得注意的是，所有这些特征图都是通过将该模型应用于未知场景而得到的。正如与图 9 相关的分析所示，该结果进一步体现了 CrossEarth 在各个领域之间的强大跨领域处理能力。更多特征图将在补充材料中展示。

六、结论

在本文中，我们提出了 CrossEarth——首个专为 RSDG 语义分割而设计的 VFM 模型。为了解决跨领域泛化问题，我们开发了两个关键组件：一是“地球风格注入”机制，该机制通过引入不同领域的训练数据来丰富训练集；二是“多任务训练”机制，该机制能够提取出适用于跨领域场景的典型语义特征。这两个组件的共同作用，从数据和模型层面提升了 DG 模型的性能。此外，为了推动 RSDG 领域的研究进展，我们仔细收集了现有的 RS 语义分割数据集，构建了一个全面的跨领域泛化评估基准，从而对模型的泛化能力进行客观评估。大量实验表明，CrossEarth 在处理涉及区域、光谱带、平台及气候等不同领域的任务时，均表现出出色的性能和灵活性，其表现优于现有的同类模型。我们提出了针对 RS 领域而定制的先进 DA 方法和 VFMs。希望这项工作能吸引 RS 领域的更多关注，推动该领域更深入的研究。同时，我们也预计 CrossEarth 将成为一个出色的基准模型，为 RSDG 领域的未来创新提供有力支持。

致谢

作者所属机构

曾阳功曾任职于中国广东省广州市的中山大学大气科学学院，邮编 519082。目前，他任职于中国上海市的上海交通大学计算机科学学院，邮编 200240。电子邮箱：
gongziyang@sjtu.edu.cn

魏志祥就职于中国科学技术大学工程科学学院，地址：中国合肥 230026（电子邮箱：
zhixiangwei@mail.ustc.edu.cn）。

王迪、张静和杜波均来自中国武汉的武汉大学计算机科学学院，邮编：430072。他们同时也在位于北京中关村的机构工作，邮编：100094。联系方式：d_wang@whu.edu.cn；
jingzhang.cv@gmail.com；dubo@whu.edu.cn

胡晓星就职于北京理工大学信息与电子学院，中国北京 100081（电子邮箱：
3120230695@bit.edu.cn）。

马贤正就职于中国武汉的武汉大学计算机科学学院，地址：武汉 430072。电子邮箱：
maxianzheng@whu.edu.cn

陈红瑞轩和横谷直人均来自日本东京大学，地址为东京 113-8654。他们同时也在日本东京 103-0027 的理化学研究所先进智能项目中心工作。联系方式：gschrx@gmail.com；
yokoya@k.u-tokyo.ac.jp

尤鲁·贾目前任职于比利时鲁汶大学的 KU Leuven 学院，该学院位于鲁汶市，邮编为 3000。同时，她也在瑞典斯德哥尔摩的 KTH 皇家理工学院工作，该学院地址为 SE-100 44 斯德哥尔摩。她的电子邮箱是 yuruj@kth.se。

邓宇鹏和朱向伟均来自中国广州的中山大学电子与通信工程学院，邮编：510275。联系方式：dengyp8@mail2.sysu.edu.cn；zhuxw666@mail.sysu.edu.cn。

季振明曾任职于中国广东省广州市的中山大学大气科学学院，邮编 519082。他现在在国家重点实验室工作。

中国科学院西北生态环境资源研究院冰冻圈科学与冻土工程研究所，中国兰州 730000（电子邮箱：jizhenming@nieer.ac.cn）

薛阳就职于上海交通大学自动化与智能感知学院，中国上海 200240（电子邮箱：yangxue-2019-sjtu@sjtu.edu.cn）。

Junchi Yan is with the School of Artificial Intelligence, Shanghai Jiao Tong University, Shanghai 200240, China (e-mail: yanjunchi@sjtu.edu.cn).

张良培就职于中国武汉的武汉大学测绘遥感信息工程国家重点实验室，地址：武汉 430079。电子邮箱：zlp62@whu.edu.cn

参考文献

- [1] M. Reichstein 等人，“深度学习与过程理解在数据驱动的地球系统科学中的应用”，《自然》杂志，第 566 卷，第 7743 期，第 195–204 页，2019 年。
- [2] M. Weiss、F. Jacob 和 G. Duveiller 著，《农业应用中的遥感技术：一项元分析》，《遥感与环境》杂志，第 236 卷，2020 年，文章编号 111402。
- [3] 朱泽等，“理解正在城市化中的地球：遥感技术的战略方向”，《遥感环境》杂志，第 228 卷，第 164–182 页，2019 年。
- [4] 魏泽、金涛，“基于深度学习的场景解析算法研究综述”，《计算机研究与发展》杂志，第 57 卷，第 4 期，第 859–875 页，2020 年。
- [5] A. Abdollahi, B. Pradhan, N. Shukla, S. Chakraborty, A. Alamri 著，《基于高分辨率遥感数据在复杂城市场景中的多目标分割》，《遥感》杂志，2021 年第 13 卷，第 18 期，文章编号：3710。
- [6] 元强等人，“环境遥感中的深度学习：成就与挑战”，《遥感与环境》杂志，第 241 卷，2020 年，文章编号 111716。
- [7] F. Dell’Acqua 和 P. Gamba 著，《遥感技术在地震灾害评估中的应用：经验、局限与展望》，《IEEE 会议记录：IRE 卷》，第 100 卷，第 10 期，第 2876–2890 页，2012 年 10 月。
- [8] 宋杰、陈浩、宣伟、夏杰、横山直树，“SynRS3D：一种用于从单目遥感图像中实现全局 3D 语义理解的合成数据集”，载于《神经信息处理系统进展》期刊，2024 年，第 117388–117425 页。
- [9] 赵 H、石 J、齐 X、王 X、贾 J：“金字塔场景解析网络”，载于《IEEE 计算机视觉与模式识别会议论文集》，2017 年，第 6230–6239 页。

- [10] 陈立春、朱勇、帕潘德里欧·G、施罗夫·F、亚当·H, “用于语义图像分割的具有空洞可分离卷积的编解码器”, 载于《2018 年欧洲计算机视觉会议论文集》, 第 801–818 页。
- [11] 傅杰等人, “用于场景分割的双注意力网络”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2019 年, 第 3141–3149 页。
- [12] 李 X 等人, “PointFlow: 基于点的流式语义处理方法在航空图像分割中的应用”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2021 年 6 月, 第 4217–4226 页。
- [13] 郑泽、钟阳、王杰、马阿。“高空间分辨率遥感图像中用于地理空间对象分割的基于前景信息的关联网”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2020 年, 第 4095–4104 页。
- [14] 郑泽、钟阳、王杰、马阿、张磊: “FarSeg++: 一种用于高空间分辨率遥感图像中地理对象分割的、能够识别前景元素的关系网络模型”, 《IEEE 模式分析与机器智能汇刊》, 第 45 卷, 第 11 期, 第 13715–13729 页, 2023 年 11 月。
- [15] 马 A、王 J、钟 Y、郑 Z: “FactSeg: 基于前景区域激活的大规模遥感图像中的小目标语义分割方法”, 《IEEE 地球科学与遥感汇刊》, 第 60 卷, 2022 年, 文章编号 5606216。
- [16] 王 L.等人, “UNetFormer: 一种类似 UNet 的变换器, 用于高效地处理遥感城市场景图像的语义分割任务”, 《ISPRS 摄影测量与遥感杂志》, 第 190 卷, 第 196–214 页, 2022 年。
- [17] D. Hong 等人, “跨城市问题: 一种用于跨城市语义分割的多模态遥感基准数据集, 该数据集基于高分辨率域适应网络进行处理”, 《遥感环境》杂志, 第 299 卷, 2023 年, 文章编号 113856。
- [18] 蔡勇、杨阳、尚勇、陈志、沈志、尹杰: “IterDANNet: 一种用于遥感图像语义分割的迭代式域内适配方法”, 《IEEE 地球科学与遥感汇刊》, 第 60 卷, 2022 年, 文章编号 5629517。
- [19] 白亮、杜森、张晓、王浩、刘斌、欧阳森: “遥感图像语义分割中的领域适应问题: 对比学习与对抗学习的集成方法”, 《IEEE 地球科学与遥感汇刊》, 第 60 卷, 2022 年, 文章编号 5628313。
- [20] 陈浩、张浩、杨刚、李森、张磊: “一种用于遥感语义分割的互信息域适应网络”, 《IEEE 地球科学与遥感汇刊》, 第 60 卷, 2022 年, 文章编号 5537316。
- [21] F. Schenkel 和 W. Middelmann, “利用卷积神经网络进行语义分割的领域适应方法”, 载于《2019 年国际地球科学与遥感研讨会论文集》, 第 728–731 页。
- [22] S. Ben-David, J. Blitzer, K. Crammer 和 F. Pereira 著, 《领域适应中的表示方法分析》, 载于《2006 年神经信息处理系统进展会议论文集》, 第 19 卷, 第 137–144 页。
- [23] Y. Ganin 和 V. Lempitsky, “通过反向传播实现无监督领域适应”, 载于《2015 年国际机器学习会议论文集》, 第 1180–1189 页。

- [24] 周阳、于泽、库马尔·B、王杰：“基于类平衡自训练的无监督领域适应方法在语义分割中的应用”，载于《2018 年欧洲计算机视觉会议论文集》，第 289—305 页。
- [25] 李阳、袁磊、Vasconcelos N.，“用于语义分割领域适应的双向学习方法”，载于《IEEE 计算机视觉与模式识别会议论文集》，2019 年，第 6929—6938 页。
- [26] 马 X 等人，“风格与‘模糊性’都很重要：基于累积领域适应的语义模糊场景理解方法”，载于《IEEE 计算机视觉与模式识别会议论文集》，2022 年，第 18900—18909 页。
- [27] 公泽、李峰、邓阳、巴塔查尔吉·D、朱晓、季泽。“CODA：一种结合严重程度感知的视觉提示调整机制的领域自适应方法”，载于《2024 年欧洲计算机视觉会议论文集》，第 130—148 页。
- [28] 龚泽等，“训练一个模型，即可泛化到所有场景：从单场景到各种复杂场景的通用语义分割方法”，载于《第 31 届 ACM 国际多媒体会议论文集》，2023 年，第 2275—2284 页。
- [29] F. Li 等人，“解析所有不良场景：基于掩码增强技术的跨域一致性语义分割方法”，载于《2024 年 AAAI 人工智能会议论文集》，第 38 卷，第 12 期，第 13483—13491 页。
- [30] 肖 A 等人，“真实环境中的 3D 语义分割：针对恶劣条件下的点云数据，构建通用性强的模型”，载于《IEEE 计算机视觉与模式识别会议论文集》，2023 年，第 9382—9392 页。
- [31] 毕 Q、游 S、格弗斯 T：“用于领域泛化城市场景分割的内容增强型掩码变换器”，载于《2024 年 AAAI 人工智能会议论文集》，第 38 卷，第 2 期，第 819—827 页。
- [32] 毕强、游森、格弗斯：“基于频率解耦的模糊场景语义分割方法”，载于《2024 年 IEEE 计算机视觉与模式识别会议论文集》，第 1389—1399 页。
- [33] 王杰等人，“泛化到未知领域：领域泛化相关研究综述”，《IEEE 知识与数据工程汇刊》，第 35 卷，第 8 期，第 8052—8072 页，2023 年 8 月。
- [34] 李 H.、潘 S.J.、王 S.和 Kot A.C.，“利用对抗性特征学习实现领域泛化”，载于《IEEE 计算机视觉与模式识别会议论文集》，2018 年，第 5400—5409 页。
- [35] J. Lambert, Z. Liu, O. Sener, J. Hays, V. Koltun 著，《MSeg：一个用于多领域语义分割的复合数据集》，载于《IEEE 计算机视觉与模式识别会议论文集》，2020 年，第 2876—2885 页。
- [36] 周凯、刘志、乔阳、向涛、Loy C.C.，“领域泛化：综述”，《IEEE 模式分析与机器智能汇刊》，第 45 卷，第 4 期，第 4396—4415 页，2023 年 4 月。
- [37] 梁超、李伟、董阳、傅伟：“基于域随机化中的类别一致性原理的遥感图像分割单域泛化方法”，《IEEE 地球科学与遥感汇刊》，第 62 卷，2024 年，文章编号 5616116。
- [38] 罗明、季森、魏森：“一个多样化的大规模建筑数据集以及一种用于建筑检测的新型即插即用式泛化方法”，《IEEE 应用地球观测与遥感专题杂志》，第 16 卷，第 4122—4138 页，2023 年。

[39] R. Iizuka, J. Xia, N. Yokoya: “基于频率的最优风格组合方法在遥感图像语义分割中的领域泛化应用”, 《IEEE 地球科学与遥感汇刊》, 第 62 卷, 2023 年, 文章编号 4501114。

[40] R. Bommasani 等人, “关于基础模型的机遇与风险”, 2021 年, arXiv:2108.07258。

[41] 王丹、张杰、杜波、夏国胜、陶丹: “遥感预训练的实证研究”, 《IEEE 地球科学与遥感汇刊》, 第 61 卷, 2023 年, 文章编号 5608020。

[42] 孙 X 等人, “RingMo: 一种基于遮蔽图像建模的遥感基础模型”, 《IEEE 地球科学与遥感汇刊》, 第 61 卷, 2023 年, 文章编号 5612822。

[43] 王 D 等人, “将普通视觉变换模型进一步发展为遥感基础模型”, 《IEEE 地球科学与遥感汇刊》, 第 61 卷, 2023 年, 文章编号 5607315。

[44] K. Cha、J. Seo 和 T. Lee 著, 《用于遥感图像的十亿级基础模型》, 《IEEE 应用地球观测与遥感领域精选期刊》, 2024 年 5 月 16 日在线发表, doi: 10.1109/JSTARS.2024.3401772。



[45] 陈凯等人, “RSPrompter: 基于视觉基础模型, 用于遥感图像分割任务的提示生成方法”, 《IEEE 地球科学与遥感汇刊》, 第 62 卷, 2024 年, 文章编号 4701117。

[46] 郭 X 等人, “SkySense: 一种用于地球观测图像的通用解析的多模态遥感基础模型”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2024 年, 第 27662–27673 页。

[47] D. Hong 等人, “SpectralGPT: 一种用于光谱遥感的基模型”, 《IEEE 模式分析与机器智能汇刊》, 第 46 卷, 第 8 期, 第 5227–5244 页, 2024 年 8 月。

[48] W. Yang 等人, “SARATR-X: 一种用于合成孔径雷达图像目标识别的基础模型”, 2024 年, arXiv:2405.09365。

[49] 王 D 等人, “HyperSIGMA: 高光谱智能理解基础模型”, 《IEEE 模式分析与机器智能汇刊》, 第 47 卷, 第 8 期, 第 6427–6444 页, 2025 年 8 月。

[50] 王 D 等人, “MTP: 通过多任务预训练提升遥感基础模型性能”, 《IEEE 应用地球观测与遥感领域精选期刊》, 第 17 卷, 第 11632–11654 页, 2024 年。

[51] 李凯、曹晓、孟丹: “基于基础模型的遥感变化检测新方法”, 《IEEE 地球科学与遥感汇刊》, 第 62 卷, 2024 年, 文章编号 5610112。

[52] M. Mendieta、B. Han、X. Shi、Y. Zhu 和 C. Chen, “通过持续预训练构建地理空间基础模型”, 载于《IEEE/CVF 国际计算机视觉会议论文集》, 2023 年, 第 16760–16770 页。

[53] 董泽、顾阳、刘涛: “UPetu: 一种用于遥感基础模型的统一参数优化微调框架”, 《IEEE 地球科学与遥感汇刊》, 第 62 卷, 2024 年, 文章编号 5616613。

[54] 王 D 等人, “SAMRS: 利用‘Segment Anything’模型来扩展遥感图像分割数据集”, 载于《Adv. Neural Inf. Process. Syst.》期刊, 2023 年, 第 36 卷, 第 8815–8827 页。

- [55] C. J. Reed 等人, “自我监督预训练方法的改进”, 载于《2022 年应用计算机视觉冬季会议论文集》, 第 2584–2594 页。
- [56] 康阳等人, “SatMAE: 用于处理时序和多光谱卫星图像的 Transformer 预训练模型”, 载于《神经信息处理系统进展》期刊, 2022 年, 第 35 卷, 第 197–211 页。
- [57] M. Oquab 等人, “DINOv2: 无需监督即可学习稳健的视觉特征”, 2023 年, arXiv:2304.07193。
- [58] T. Brown 等人, “语言模型属于少样本学习器”, 载于《神经信息处理系统进展》会议论文集, 2020 年, 第 33 卷, 第 1877–1901 页。
- [59] A. Chowdhery 等人, “PALM: 利用路径机制实现语言建模的规模化处理”, 《机器学习研究杂志》, 第 24 卷, 第 240 期, 第 1–113 页, 2023 年。
- [60] H. Touvron 等人, “LLaMa: 开放且高效的通用语言模型”, 2023 年, arXiv:2302.13971。
- [61] 王 X、王 W、曹 Y、沈 C、黄 T: “图像以图像的形式传递信息: 一种适用于上下文感知视觉学习的通用算法”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2023 年, 第 6830–6839 页。
- [62] A. Bar、Y. Gandelsman、T. Darrell、A. Globerson 和 A. Efros, “通过图像修复实现视觉提示”, 载于《Adv. Neural Inf. Process. Syst.》期刊, 2022 年, 第 35 卷, 第 25005–25017 页。
- [63] 王 X、张 X、曹 Y、王 W、沈 C、黄 T, “SegGPT: 在上下文中对所有内容进行分割”, 2023 年, arXiv:2304.03284。
- [64] 白阳等人, “序列建模有助于大型视觉模型的高效训练”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2024 年, 第 22861–22872 页。
- [65] 王伟等人, “InternImage: 利用可变形卷积来探索大规模视觉基础模型”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2023 年, 第 14408–14419 页。
- [66] 何凯、陈晓、谢松、李阳、多拉尔·P.和吉尔希克·R., “掩码自编码器是一种具有良好扩展性的视觉学习方法”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2022 年, 第 15979–15988 页。
- [67] 刘 H、李 C、吴 Q、李 Y.J., “视觉指令的调整方法”, 载于《神经信息处理系统进展》论文集, 2024 年, 第 36 卷, 第 34892–34916 页。
- [68] 王伟等人, “VisionLLM: 大型语言模型也可以作为以视觉任务为核心的任务的解码器”, 载于《神经信息处理系统进展》期刊, 2024 年, 第 36 卷, 第 61501–61513 页。
- [69] 陈泽等人, “InternVL: 提升视觉基础模型的性能, 并使其适用于各种视觉–语言任务”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2024 年, 第 24185–24198 页。
- [70] J. Achiam 等人, “GPT–4 技术报告”, 2023 年, arXiv:2303.08774。

- [71] L. Scheibenreif、M. Mommert 和 D. Borth 著,《参数效率高的自监督式地理空间域适应方法》,载于《2024 年 IEEE 计算机视觉与模式识别会议论文集》,第 27841–27851 页。
- [72] M. Pirvu, A. Marcu, M. A. Dobrescu, A. N. Belbachir 和 M. Leordeanu,“利用地球观测数据进行半监督学习的多任务超图模型”,载于《IEEE/CVF 国际计算机视觉会议论文集》,2023 年,第 3396–3406 页。
- [73] L. P. Osco 等人,“用于遥感应用的‘分段处理模型’:从无到有的突破”,《国际应用地球观测与地理信息学杂志》,第 124 卷,2023 年,文章编号 103540。
- [74] P. W. Koh 等人,“Wilds: 一种衡量数据在真实环境中分布变化的基准测试方法”,载于《2021 年国际机器学习会议论文集》,第 5637–5664 页。
- [75] 姚浩、杨晓、潘晓、刘森、柯佩文、芬恩·C.,“利用领域关系提升模型的泛化能力”,载于《2024 年国际学习表示会议论文集》。
- [76] 赵阳、钟哲、赵楠、Sebe N.和 Lee G. H.,“基于风格幻觉的双一致性学习:视觉领域泛化的统一框架”,《国际计算机视觉杂志》,第 132 卷,第 3 期,第 837–853 页,2024 年。
- [77] Y. Long 等人,“关于构建航空图像解读领域的基准数据集:综述、指导原则与百万级数据集的构建”,《IEEE 应用地球观测与遥感领域精选期刊》,第 14 卷,第 4205–4230 页,2021 年。
- [78] L. Hoyer、D. Dai、H. Wang 和 L. Van Gool 著,“MIC: 用于增强型领域适应的遮蔽图像一致性处理方法”,载于《IEEE 计算机视觉与模式识别会议论文集》,2023 年,第 11721–11732 页。
- [79] P. T. Jackson, A. A. Abarghouei, S. Bonner, T. P. Breckon, B. Obara 著,《风格增强:通过风格随机化实现数据增强》,载于《2019 年 IEEE 计算机视觉与模式识别会议论文集》,第 6 卷,第 10–11 页。
- [80] 王杰、郑志、马阿、卢晓、钟阳,“LoveDA: 一种用于领域自适应语义分割的遥感土地覆盖数据集”,2021 年,arXiv:2110.08733。
- [81] 陈伟、江泽、王哲、崔凯、钱晓,“用于超高分辨率图像的高效分割的协作式全局–局部网络”,载于《IEEE 计算机视觉与模式识别会议论文集》,2019 年,第 8916–8925 页。
- [82] V. Mnih,《用于航空图像标注的机器学习方法》,博士论文,多伦多大学计算机科学系,加拿大安大略省多伦多市,2013 年。
- [83] M. Rahnemoonfar、T. Chowdhury 和 R. Murphy 著,《RescueNet: 用于自然灾害损失评估的高分辨率无人机语义分割基准数据集》,《科学数据》杂志,第 10 卷,2022 年,文章编号 913。
- [84] 夏杰、横山直树、阿德里亚诺·B.和布罗尼–贝迪亚科·C.,“OpenEarthMap: 用于全球高分辨率土地覆盖绘制的基准数据集”,载于《2023 年 IEEE/CVF 应用计算机视觉冬季会议论文集》,第 6243–6253 页。

- [85] 陆 X、钟 Y、郑 Z、陈 D: “GRE 及更广泛的道路提取数据集”, 载于《IEEE 国际地球科学与遥感研讨会论文集》。IEEE, 2022 年, 第 3035–3038 页。
- [86] 吴思杰、魏森、卢明: “基于全卷积网络的多源航空与卫星图像建筑提取方法”, 《IEEE 地球科学与遥感汇刊》, 第 57 卷, 第 1 期, 第 574–586 页, 2019 年 1 月。
- [87] 刘 S、陈 L、张 L、胡 J、傅 Y: “用于领域自适应土地覆盖语义分割的大规模气候敏感卫星图像数据集”, 《ISPRS 摄影测量与遥感杂志》, 第 205 卷, 第 98–114 页, 2023 年。
- [88] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov 和 R. Girdhar 著, 《用于通用图像分割的掩码注意力变换器》, 载于《2022 年 IEEE 计算机视觉与模式识别会议论文集》, 第 1280–1289 页。
- [89] 魏泽等人, “更强大、更简洁、更出色: 利用视觉基础模型实现领域泛化的语义分割”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2024 年 6 月, 第 28619–28630 页。
- [90] Y. LeCun 等人, “反向传播在手写邮政编码识别中的应用”, 《神经计算》杂志, 第 1 卷, 第 4 期, 第 541–551 页, 1989 年。
- [91] X. Glorot、A. Bordes 和 Y. Bengio 著, 《深度稀疏整流器神经网络》, 载于《2011 年国际人工智能与统计学会会议论文集》, 第 315–323 页。
- [92] 黄泽、王晓、黄磊、黄晨、魏阳、刘伟: “CCNet: 一种用于语义分割的交叉注意力机制”, 载于《IEEE/CVF 国际计算机视觉会议论文集》, 2019 年, 第 603–612 页。
- [93] F. Milletari、N. Navab 和 S.-A. Ahmadi 著, “V-Net: 用于体积医学图像分割的全卷积神经网络”, 载于《2016 年国际 3D 视觉会议论文集》, 第 565–571 页。
- [94] 张锋、石勇、熊志、黄伟、朱晓霞: “基于伪特征的自我训练方法在卫星图像语义分割中的应用”, 《IEEE 地球科学与遥感汇刊》, 第 61 卷, 2023 年, 文章编号 5612414。
- [95] 梁超、程波、肖斌、董阳、陈杰: “用于遥感图像分割的多层次异构域适应方法”, 《IEEE 地球科学与遥感汇刊》, 第 61 卷, 2023 年, 文章编号 5601916。
- [96] 梁超、程波、肖斌、董阳: “基于对抗学习和自训练的无监督领域适应方法在遥感图像分割中的应用”, 《IEEE 地球科学与遥感快报》, 第 20 卷, 2023 年, 文章编号 6006005。
- [97] I. Demir 等人, “DeepGlobe 2018: 一项利用卫星图像解析地球表面的挑战性任务”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2018 年, 第 172–17209 页。
- [98] L. Hoyer、D. Dai 和 L. Van Gool 著, “DAFormer: 用于领域自适应语义分割的网络架构与训练策略改进”, 载于《IEEE 计算机视觉与模式识别会议论文集》, 2022 年, 第 9924–9935 页。
- [99] 谢 E、王 W、于 Z、阿南德库马尔 A、阿尔瓦雷斯 J.M.和罗 P, “SegFormer: 一种基于 Transformer 的语义分割方法——简单高效的设计方案”, 载于《神经信息处理系统进展》期刊, 2021 年, 第 34 卷, 第 12077–12090 页。

[100] L. Hoyer、D. Dai 和 L. Van Gool 著,“HRDA: 一种具有情境感知能力的高分辨率领域自适应语义分割方法”,载于《2022 年欧洲计算机视觉会议论文集》,第 372–391 页。

[101] A. Stewart 等人,“SSL4EO–L: 用于 Landsat 影像的数据集与基础模型”,载于《Adv. Neural Inf. Process. Syst.》期刊,2023 年,第 36 卷,第 59787–59807 页。

[102] A. Dosovitskiy 等人,“一张图片相当于 16×16 个单词的信息量: 用于大规模图像识别的 Transformer 模型”,2020 年,arXiv:2010.11929。

[103] 熊泽等人,“受神经可塑性启发的地球穿越现象观测模型”,CoRR,2024 年。[在线阅读]。可访问地址: <https://doi.org/10.48550/arXiv.2403.15356>



[104] C. J. Reed 等人,“Scale–MAE: 一种具有尺度感知能力的掩码自编码器,用于多尺度地理空间表示学习”,载于《IEEE/CVF 国际计算机视觉会议论文集》,2023 年,第 4065–4076 页。

[105] 刘 F.等人,“RemoteCLIP: 一种用于遥感的视觉语言基础模型”,《IEEE 地球科学与遥感汇刊》,第 62 卷,2024 年,文章编号 5622216。

[106] 王阳、N. A. A. Braham、熊泽、刘晨、C. M. Albrecht 和朱晓霞:“SSL4EO–S12: 一个用于地球观测领域自监督学习的大规模多模态、多时相数据集[软件与数据集]”,《IEEE 地球科学与遥感杂志》,第 11 卷,第 3 期,第 98–106 页,2023 年 9 月。

[107] L. Hoyer、D. Dai 和 L. Van Gool 著,《用于语义图像分割的领域自适应且具有泛化能力的神经网络架构与训练方法》,《IEEE 模式分析与机器智能汇刊》,第 46 卷,第 1 期,第 220–235 页,2024 年 1 月。

[108] I. Loshchilov,《解耦型权重衰减正则化方法》,2017 年,arXiv:1711.05101。

[109] 陈立春、G. Papandreou、F. Schroff 和 H. Adam,“重新思考用于语义图像分割的无孔卷积算法”,2017 年,arXiv:1706.05587。

[110] 何凯、张晓、任森、孙杰:“用于图像识别的深度残差学习方法”,载于《IEEE 计算机视觉与模式识别会议论文集》,2016 年,第 770–778 页。

[111] 陈立春、G. Papandreou、I. Kokkinos、K. Murphy 和 A. L. Yuille,“DeepLab: 利用深度卷积网络、空洞卷积以及全连接条件随机场进行语义图像分割”,《IEEE 模式分析与机器智能汇刊》,第 40 卷,第 4 期,第 834–848 页,2018 年 4 月。

[112] L. McInnes、J. Healy 和 J. Melville 著,《UMAP: 用于降维的均匀流形近似与投影方法》,2018 年,arXiv:1802.03426。

魏志祥于 2021 年从中国合肥的安徽大学获得了通信工程学士学位。目前,他正在中国合肥的中国科学技术大学工程科学学院攻读精密机械与精密仪器专业的博士学位。他的研究兴趣包括图像分割和深度学习领域。

王迪 (IEEE 会员) 于 2018 年在中国青岛的中国石油大学 (华东) 获得了测绘工程学士学位。2020 年, 他又从中国武汉的武汉大学测绘遥感信息工程国家重点实验室获得了工程硕士学位。目前, 他正在武汉大学计算机科学学院攻读博士学位。他的研究领域包括计算机视觉和遥感技术。

胡晓星 (IEEE 学生会员) 于 2023 年从中国长沙的中南大学获得学士学位。目前, 他正在北京理工大学攻读硕士学位。他的研究兴趣包括遥感图像处理和多模态学习。

马贤政在中国武汉的武汉大学计算机科学学院获得了学士和硕士学位。他目前正在英国牛津大学攻读博士学位。他的研究领域包括多模态 3D 理解与 3D 计算机视觉。

陈鸿瑞轩 (IEEE 会员) 于 2019 年在中国合肥的安徽大学获得工学学士学位, 2022 年在中国武汉的武汉大学获得工学硕士学位。目前, 他正在日本千叶市的东京大学前沿科学研究生院攻读博士学位。同时, 他也是瑞士苏黎世联邦理工学院的访问学者。

邹阳功 (IEEE 学生会员) 毕业于中国珠海的中山大学大气科学学院, 获得资源与环境工程专业的工学学位。他目前在上海交通大学的计算机科学学院攻读博士学位。他曾在上海人工智能实验室和清华大学担任研究助理。他的研究兴趣包括遥感技术和具身人工智能。

于璐佳在中国南京的东南大学获得了地理信息科学学士学位, 又在瑞士苏黎世联邦理工学院获得了测绘学硕士学位。目前, 她正在鲁汶大学测绘学系与瑞典皇家理工学院地理信息学系联合攻读博士学位。她的研究领域包括自监督学习、生成模型以及地球观测技术。

邓宇鹏 (IEEE 会员) 在中山大学获得了电信专业学士学位, 在新加坡国立大学获得了机器人学专业硕士学位。他目前是中山大学的研究助理, 师从朱向伟教授。他的研究领域包括计算机视觉和具身人工智能。

季振明目前是中山大学大气科学学院的副教授。他主要从事地球系统模型的研发工作, 以及人工智能技术在气象领域的应用研究。他在《自然-地球与环境评论》、《自然-通讯》和《环境遥感》等期刊上发表了 70 多篇学术论文。

朱向伟 (IEEE 会员) 毕业于中国长沙的国防科技大学, 获得博士学位。他目前是中国深圳中山大学电子与通信工程学院的教授。他的研究领域包括全球导航卫星系统、时间同步、智能信号处理以及仪器设计。

薛阳 (IEEE 会员) 于 2016 年在中国湖南的中南大学获得自动化专业学士学位, 2019 年在中国北京的中国科学院大学获得硕士学位, 2023 年在中国上海的上海交通大学获得计算机专业博士学位。目前, 他担任上海交通大学自动化与智能感知学院的助理教授。

横谷直人 (IEEE 会员) 目前是东京大学的副教授, 同时也在日本东京的理化学研究所先进智能项目组担任负责人, 负责领导该组的地理信息学相关研究工作。2013 年至 2017 年间, 他担任东京大学的助理教授。自 2021 年起, 他开始担任《IEEE 地球科学与遥感汇刊》的副主编; 自 2024 年起, 他还开始担任《J P&RS》杂志的副主编。2022 年, 他被 Clarivate 评为“高被引研究人员”。

张晶 (IEEE 高级会员) 曾是悉尼大学计算机科学学院的研究员。他在 CVPR、ICCV、ECCV、NeurIPS、ICLR、《IEEE 模式分析与机器智能汇刊》以及《IJCV》等知名学术会议和期刊上发表了 80 多篇论文。他的研究领域包括计算机视觉和深度学习。此外, 他还担任 ICPR 的领域主席, AAAI 和 IJCAI 的程序委员会高级成员, 以及《IEEE 大数据汇刊》的特邀编辑。

Bo Du (IEEE 高级会员) 目前是计算机科学学院的教授, 同时担任国家多媒体软件工程研究中心的主任。他曾荣获 Clarivate“高被引研究人员”称号 (2019—2024 年)、2018 年 IJCAI 杰出论文奖、2018 年 IEEE WHISPERS 最佳论文奖以及 2020 年 IEEE GRSS Transactions 奖。此外, 他还担任《IEEE 图像处理汇刊》、《IEEE 电路与系统视频技术汇刊》等期刊的副主编。

神经网络与学习系统、概率论与数理统计、神经网络相关内容。

同时, 我还是 IAPR/IET 的会员。

严俊奇 (IEEE 高级会员) 目前是中国上海交通大学人工智能学院的教授。他曾在 IBM 研究院担任研究员。他的研究领域包括机器学习和计算机视觉。他曾担任 ICLR、ICML、NeurIPS、SIGKDD 和 CVPR 等会议的领域主席, 同时还是《IEEE 模式分析与机器智能汇刊》的副主编以及 ICML 的董事会成员。他的研究成果被选为 CVPR 2024 的最佳论文候选篇目和 ACL 2025 的杰出论文。

张良培 (IEEE 会士) 目前担任由中国教育部任命的“长江学者”特聘教授, 同时也在武汉大学担任测绘遥感信息工程国家重点实验室的教授。2011 年至 2016 年期间, 他作为中国国家科技部重点基础研究项目的首席科学家, 负责该领域的研发工作。他独自或与他人共同发表了 700 多篇研究论文, 并撰写了 5 本书籍。此外, 他还担任着该研究所的负责人。

他是科学信息研究所 (ISI) 评选出的高被引学者, 同时拥有 30 项专利。他的研究领域包括高光谱遥感、高分辨率遥感、图像处理以及人工智能。他还担任《IEEE 地球科学与遥感汇刊》的副主编。此外, 他还是英国工程技术学会的会员。